

代 号	10701	学 号	1075190223
分 类 号	TN953	密 级	公开
U D C		编 号	

题（中、英文）目 多目标跟踪的数据关联算法研究

Research On Data Association Algorithms

Of Multi-target Tracking

作 者 姓 名 吴佳芯 学校指导教师姓名职称 李明 教授

工 程 领 域 电子与通信工程 企业指导教师姓名职称 阮锋 高工

论 文 类 型 应用基础技术 提交论文日期 二〇一三年一月

西安电子科技大学

学位论文独创性（或创新性）声明

秉承学校严谨的学风和优良的科学道德，本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果；也不包含为获得西安电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

西安电子科技大学 关于论文使用授权的说明

本人完全了解西安电子科技大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属西安电子科技大学。学校有权保留送交论文的复印件，允许查阅和借阅论文；学校可以公布论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存论文。同时本人保证，毕业后结合学位论文研究课题再撰写的文章一律署名为西安电子科技大学。

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

摘要

随着现代武器战术性能的提高以及电子干扰技术的发展，多目标跟踪技术在国防领域得到广泛的应用。数据关联是多目标跟踪最困难也是最核心的技术之一，决定着多目标跟踪的整体性能，因此受到国内外学者与工程专家的高度关注。

本文研究了最近邻算法、概率数据互联算法、联合概率数据互联算法、交互式多模型概率数据关联算法等经典的数据关联算法。针对联合概率数据互联算法在跟踪目标数目与回波数目增多时计算量爆炸的问题，给出了三种解决方案：给出了改进的快速数据关联算法，避开联合关联假设事件的产生，缩小公共回波的权值，扩大非公共回波的权值，从而保证了跟踪的性能，避免了计算量的迅速增长；在传统跟踪波门的基础上，引入方向跟踪门，减少有效回波的个数，从而减少联合概率互联算法的计算量；采用最大熵模糊聚类算法实现数据关联，并对权值的再分配问题进行研究；最后通过仿真验证了算法的有效性。

关键词：多目标跟踪 数据关联 联合概率数据关联 方向跟踪门 最大熵模糊聚类

Abstract

With the development of modern weapons' tactical performance and electronic jamming technology, techniques of multi-target tracking have been widely used in national defense areas. As one of the most core and difficult techniques in the multi-target tracking, the technique of data association determines the multi-target tracking system's performance. So, many engineering specialists and scholars at home and abroad have paid much attention to the development of data association technology.

The dissertation studied some classical data association algorithms, including Nearest Neighbor algorithm、Probabilistic Data Association algorithm、Joint Probabilistic Data association algorithm、Interacting Multiple Model estimator with Probabilistic Data Association filter. With the increase of targets and measurements, the load of Joint Probabilistic Data Association algorithm computation grows rapidly. Aiming at this defect, the dissertation gave three solutions. First of all, a modified fast data association algorithm has been proposed. In order to guarantee the tracking performance and avoid rapid growth calculation, the algorithm avoids the creation of the joint related hypothesis events, reduces public measurements' weight, and expands the non-public measurements' weight. Secondly, the two-tracking-gate, in which contains a traditional gate and a direction gate, was introduced to reduce the effective measurements' number, thus reduce the load of Joint Probabilistic Data Association algorithm computation. In the end, the Maximum Entropy Fuzzy Clustering algorithm was introduced for data association, and the effect of public measurement on the update of tracks' state is analyzed. Finally, these methods have been proved to be effective by simulation.

Keywords: Multi-target Tracking Data Association Joint Probabilistic Data Association Direction Tracking Gate Maximum Entropy Fuzzy Clustering

目 录

第一章 绪论	1
1.1 论文研究的背景与意义	1
1.2 国内外研究现状与发展趋势	1
1.3 本文的主要内容	3
第二章 多目标跟踪及数据关联的基本理论	5
2.1 多目标跟踪的基本理论	5
2.1.1 跟踪起始与终结	5
2.1.2 目标运动模型	6
2.1.3 跟踪门技术	6
2.1.4 滤波与预测	7
2.2 目标运动模型	7
2.2.1 CA 与 CV 模型	7
2.2.2 时间相关模型	8
2.2.3 转弯模型	9
2.3 数据关联算法	10
2.3.1 最近邻域法	10
2.3.2 概率数据关联算法	10
2.3.3 联合概率数据互联算法	13
2.3.4 其他的经典算法	15
2.4 交互式多模型算法	17
2.4.1 交互式多模型算法	18
2.4.2 交互式多模型概率数据关联算法	21
2.5 仿真结果及分析	22
2.5.1 概率数据互联算法	22
2.5.2 交互式多模型算法	23
2.5.3 交互式多模型概率数据关联算法	25
2.5.4 联合概率数据互联算法	27
2.6 本章小结	28
第三章 联合概率数据关联算法的改进	29
3.1 经验联合概率数据关联算法	30
3.2 修正的联合概率数据关联算法	30
3.2.1 算法实现	31
3.2.2 仿真结果与分析	33
3.3 基于联合概率数据关联算法的多重门限研究	38
3.3.1 方向跟踪门的构造方法	38
3.3.2 仿真结果与分析	40
3.4 本章小节	42
第四章 基于模糊聚类的多目标数据关联算法	43
4.1 C-均值聚类算法	43
4.2 改进的最大熵模糊联合概率数据关联算法	44

4.2.1 改进的最大熵模糊聚类.....	44
4.2.2 最佳差异因子 $\alpha_{i(opt)}$	45
4.2.3 算法实现.....	47
4.3 仿真结果与分析.....	48
4.3.1 两个目标交叉运动.....	49
4.3.2 四个近距离平行目标.....	50
4.3.3 四个小角度交叉目标.....	52
4.4 本章小节.....	53
第五章 结束语	55
5.1 工作总结.....	55
5.2 工作展望.....	55
致谢.....	57
参考文献	59

第一章 绪论

1.1 论文研究的背景与意义

随着科学技术的迅猛发展,现代战争已由海、陆、空三维战争,发展到海、陆、空、天、电磁五位一体的立体战争,空中武器的机动性、杀伤力、命中精度、射程和速度等战术性能大大提高,传统的雷达防空系统越来越多地面临着隐身目标攻击、电子对抗、反辐射武器攻击和低空突防这四大威胁。控制技术、信号检测与处理技术、计算机技术、网络通信技术以及微电子技术的迅猛发展,导致多传感系统的大量涌现。与传统的雷达防御系统相比,被动多传感器探测系统不需要发射电磁波,仅利用目标自身辐射的信号进行探测与跟踪,具有良好的隐蔽性,能够提升防御系统在复杂的电子战环境下的生存能力。

被动多传感器探测器系统一般由多个传感器构成传感器网络,将多个传感器得到的目标方位、距离进行信息融合以协同跟踪,其优点是跟踪精度高,搜索范围大。随着数字信号处理技术和传感器技术的不断发展,被动传感器的制造成本不断降低,功能不断增强。欧美国家相继展开被动多传感器信息融合系统的研发工作,并取得长足发展,很多理论成果已付诸于工程应用。而我国在被动多传感器信息融合领域的研究起步较晚,技术相对落后,国外的先进技术资料保密程度较高,因此,我国应该加大相关研究的投入。

多目标跟踪理论作为信息融合领域的一个难点问题与重要分支,其发展历程可追溯到第二次世界大战前夕,即 1937 年世界上出现的第一部雷达 SCR-28。之后,各种声纳、激光、红外和雷达等目标跟踪系统先后得到发展并且日趋完善。美国的区域导弹防御系统 TMD (Territorial Missile Defense) 和国家导弹防御系统 NMD (National Missile Defense),其核心技术之一就是多目标跟踪。

多目标跟踪技术涉及多个领域,包括量测的录取、航迹起始、数据关联、跟踪维持、航迹消除、性能评估等内容,其中数据关联与状态估计是多目标跟踪技术的核心部分。近年来,随着电子对抗技术的发展,目标机动性能的不断改善,被测目标的不确定性越来越复杂,目标跟踪问题发生了深刻变化,进一步表现出非高斯、不确定、非线性、多尺度、高维数等特点。多目标跟踪技术的概念是 1995 年由 Wax 提出的,以 Singer、Bar-Shalom、S.S.Blackman 为代表的大批科学家推动了多目标跟踪技术的发展。尽管如此,多目标跟踪仍是一项非常复杂的、跨学科的研究课题,没有一种通用方法可以适用于各种跟踪环境。多目标跟踪是未来战争中关键技术,包括我国在内的很多国家都已经将它列为未来重点发展的国防技术之一。多目标跟踪技术决定了信息融合系统的性能,从而影响战争的胜负成败。

因此, 我们应该积极开展多目标跟踪技术的研究, 以提高我国国防系统的防御能力。

1.2 国内外研究现状与发展趋势

多目标跟踪作为数据融合领域最活跃、成果最丰富的重要分支, 已有五十多年的发展历程。数据关联是多目标跟踪中核心技术之一, 相关的研究非常多, 其突破始于上个世纪 70 年代。

1971 年, R.A.Singer 和 R.G.Sea^[1]提出了最近邻算法, 认为在某一时刻的所有量测中, 距离与被跟踪目标预测位置最近的量测应该作为目标的真实量测, 并预测目标在下一时刻的预测位置。实际上, 目标的真实量测未必与目标的预测位置最近, 因此, 最近邻算法在杂波环境下容易导致目标的丢失或误跟。1972 年, Bar-Shalom 和 Tse 提出了概率数据互联算法, 将跟踪波门中所有量测进行概率意义上的加权平均作为滤波输出。随后, Shalom 又针对多个目标跟踪门相交情况进行了详尽的研究, 提出了确认矩阵的概念, 将概率数据互联算法推广为适用于多目标跟踪的联合概率数据互联算法^[2]; 80 年代末, 又提出了最优联合概率数据互联算法。此后, B.Zhou, D.Musicki 和 J.A.Roecker 等学者对联合概率数据互联算法进行改进, 分别提出了快速联合概率数据互联算法^[3]、综合概率数据互联算法和次优联合概率数据互联算法等改进算法。

此外, 20 世纪 70 年代中期到 80 年代末, D. B. Reid、S. S. Blackman、C. Y. Chong、W. D. Blair、R. Singer、H. A. P. Blom 等科学家在机动目标跟踪和数据关联方面也作出了杰出的贡献, 提出了许多经典算法, 如分层融合算法、多假设法、Singer 模型算法、交互式多模型算法等。上个世纪 90 年代后, S. Mori、P. Willett、T. Kirubarajan、D. Musicki、X. R. Li、A. Poore 等科学家对综合概率数据关联算法、概率多假设跟踪算法、变结构 IMM 算法以及多维分配算法在多目标跟踪中的应用进行了研究。2000 年以后, R. Mahler, B. N. Vo, N. Gordon, A. Doucet, J. Godsill 等学者对基于随机集理论的多目标跟踪以及粒子滤波进行研究, 并取得大量的研究成果, 给多目标跟踪技术的发展注入了新的活力。

与欧美国家在多目标跟踪领域的蓬勃发展相比, 国内的相关技术研究起步较晚。海湾战争后, 该领域受到相关部门的重视, 开展相关研究的单位有^[4-10]: 中电 29 所、中电 14 所、中电 38 所、中电 28 所、中科院电子所、航天科工集团及科技集团、清华大学、西安电子科技大学、西安交通大学、西北工业大学、哈尔滨工业大学、北京航空航天大学、上海交通大学、华中科技大学等。他们在多传感器融合跟踪与定位、分布检测融合^[11]、机动目标跟踪^[12]、目标识别与决策信息融合等领域积极展开研究, 并在组网雷达数据处理、导航与制导、战区指挥自动化等

领域研制出一批目标跟踪系统。

学术方面, 1995年在长沙召开了第一次信息融合学术会议。90年代以来, 孙仲康、韩崇昭、潘泉、保铮、周宏仁、敬忠良、吴顺君、何友、权太范、沈正康等学者及其研究团队在信息融合领域做了大量的工作, 取得了一大批理论研究成果, 如: 平方根卡尔曼滤波、当前机动模型、基于方位量测及其变化率的无源定位算法、模糊航迹关联、基于神经网络的机动目标跟踪等。一些有关目标跟踪和信息融合的学术著作和译著^[13]得以出版, 代表性的著作包括: 《机动目标跟踪》、《目标跟踪新理论与技术》、《雷达数据处理及应用》、《数据融合理论及其应用》、《相控阵雷达数据处理及其仿真技术》、《数据融合技术及其应用》、《多传感器信息融合及应用》、《雷达信号处理和数据处理技术》、《神经网络跟踪理论及应用》、《数据融合方法概论》、《信息融合: 神经网络-模糊推理理论及应用》。尽管如此, 在多目标理论研究和应用实践方面, 与国外先进国家相比, 我国仍有较大的差距, 需要进一步深入研究与投入赶超国际先进水平。

1.3 本文的主要内容

本文主要工作是对多目标跟踪中数据关联算法的研究。文章简述了多目标跟踪的基本理论, 研究了最近邻算法、概率数据关联算法、联合概率数据关联算法、多假设法、交互式多模型算法等经典的多目标跟踪算法, 对算法进行了仿真分析, 讨论了各算法的适用的范围以及优缺点。文章针对联合概率数据关联算法存在的问题提出了相应的解决方案, 并仿真分析了各个方案的可行性。

本文的主要工作和各章内容安排如下:

第一章: 绪论。主要研究了本文的研究背景、意义、多目标跟踪系统, 概述了多目标跟踪技术的发展现状, 最后给出了本文的内容安排。

第二章: 多目标跟踪及数据关联的基本理论。简述了多目标跟踪系统的基本理论, 研究了经典的数据关联算法, 并进行了仿真分析。

第三章: 联合概率数据关联算法的改进。针对联合概率数据关联算法存在的问题, 提出了改进的快速数据关联算法, 避开关联事件的产生, 缩小公共回波的权值, 扩大非公共回波的权值; 在传统跟踪波门的基础上, 引入方向跟踪门, 减少有效回波的个数, 从而减少联合概率互联算法的计算量, 通过仿真实验验证了算法的有效性。

第四章: 基于模糊聚类的多目标数据关联算法研究。引入最大熵模糊联合概率数据关联算法对目标进行跟踪, 最后通过仿真实验验证了算法的有效性。

第五章: 总结与展望。总结本文的主要工作。

第二章 多目标跟踪及数据关联的基本理论

现在多目标跟踪技术的研究都已经取得了长足的发展,涌现出了大量的多目标跟踪算法,多目标跟踪已成为一门涉及多个学科与领域的综合性理论。从系统的角度,多目标跟踪可以分为以下几个环节:量测数据的处理、航迹起始与终结、跟踪维持、跟踪门的形成、数据关联等。其中,数据关联是多目标跟踪最核心的部分,其主要作用是将量测数据与已有航迹进行配对,以确定它们是否来自于同一个目标。

本章主要阐述了多目标跟踪的基本理论,对多目标跟踪的基本环节做了一个较为全面的概述,包括目标运动模型、数据关联算法、跟踪门的设计、航迹起始与终结、跟踪维持;研究了几种经典的数据关联算法,并进行仿真分析。

2.1 多目标跟踪的基本理论

目标跟踪过程可以定义为估计目标在当前时刻(滤波)和未来(外推)任意时刻状态的过程。目标的状态包括各种运动的或者描述性的参数,一般地,运动参数具有最重要的意义。目标的状态估计是在两种不确定性下进行的。第一种是目标运动模型的不确定性。由于大多数目标在未来的时间段内可能做已知或未知的机动,因此,目标的运动模型存在着不确定性。一般情况下,目标的非机动及机动运动都可以通过不同的数学模型加以描述。在进行目标跟踪的过程中,采用不正确的目标运动模型会导致系统的跟踪性能严重下降。第二种是量测的不确定性。量测的不确定性是指传感器系统提供的量测可能来自是外部的数据干扰,它可能是由杂波、虚警和相邻的目标所引起的。量测作用点不能总是正确的确定,量测含有噪声,这两个因素造成了量测的不确定性。这种不确定性在本质上是离散的,给多目标跟踪提出了极大的挑战,相应的就产生了数据关联的问题。

图 2.1 给出了多目标跟踪的基本原理。多目标跟踪主要包含以下几个基本要素:跟踪起始与终结、跟踪门的形成、数据关联、跟踪维持等。多目标跟踪的关键在于如何有效地进行数据关联。

2.1.1 跟踪起始与终结

航迹起始与终结是多目标跟踪理论中的两个重要组成部分。航迹起始是目标跟踪的首要任务,是对新目标建立跟踪档案的决策方法,主要包括假定航迹初始化和航迹确定两部分。通常不与已知目标轨迹相关的观测用于形成新的暂时航迹,并进行航迹初始化。传统的跟踪起始方法有 N 维分配法、序列概率比检验 (SPRT)、

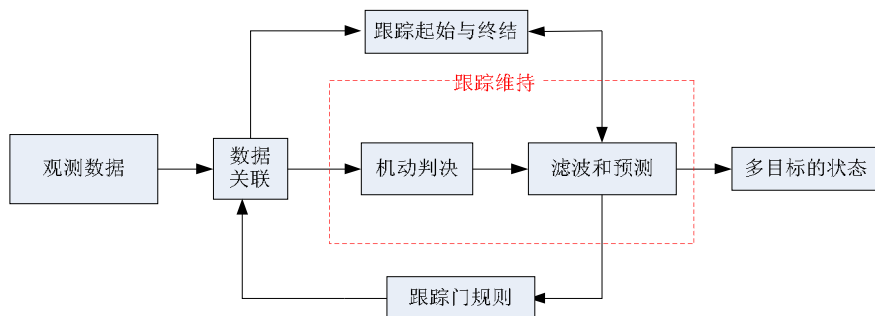


图 2.1 多目标跟踪的基本原理

Bayes 轨迹确定方法、模式匹配技术及极大似然法。前三种方法一般只适用于稀疏回波环境，对于密集回波环境，必须采用能够同时处理航迹初始化和航迹确定的批处理算法，如模式匹配法和极大似然法。

在工程中，常用的航迹起始算法包括直观法、逻辑法、修正的逻辑法^[14]等。此外，图像处理中的 Hough 变换算法在强杂波背景下也是一种良好的航迹起始算法，但是仅适用于直线运动目标、需要较长的起始时间及计算量较大等方面的弱点，使其不适合于工程应用。

跟踪终结即轨迹终结，即消除多余目标的档案。主要方法主要有全邻 Bayes 算法、跟踪门法、序贯概率比检验（SPRT）算法、代价函数法。

2.1.2 目标运动模型

目标运动模型的研究是多目标跟踪技术研究的一个重要方面。20 年来，不少学者对此进行了深入的研究。根据目标是否机动，可以分为两大类：一类是非机动模型，主要有匀速（CV）模型和匀加速（CA）模型；另一类是机动目标模型，主要有时间相关模型和当前统计模型、转弯（CT）模型。其他经典的模型还包括微分多项式模型、转弯模型、半马尔科夫模型、Noval 统计模型等。

2.1.3 跟踪门技术

跟踪波门^[15]的形成是多目标跟踪首当其冲的问题，跟踪门是以被跟踪目标的预测位置为中心，用来确定该目标的观测值可能出现的范围的一片区域。波门的大小由正确接收回波的概率来确定，在确定波门形状与大小时，应使真实量测以很高的概率落入波门中，同时又要使波门中的无关量测的数量不是很多，落入跟踪波门中的回波被称为有效（候选）回波。跟踪门是将观测值分配给已建立的目标航迹或者确定新的目标航迹的一种粗略的检测方法，其作用有两个：

1) 当观测值落入某个目标的跟踪门内时，该观测值被考虑用于目标航迹状态的更新。

2) 如果观测值没有落入任何目标的跟踪门内, 则认为观测值可能来自于新的目标或者虚警。

常用的跟踪门有矩形波门、椭圆(球)波门、环形波门与极坐标下的扇形波门。

2.1.4 滤波与预测

滤波与预测是跟踪系统最基本的要素, 是估计当前时刻与未来时刻目标的运动参数如位置、速度、加速度的必要手段。当跟踪非机动或弱机动目标时, 常用 $\alpha-\beta$ 滤波、 $\alpha-\beta-\gamma$ 滤波、卡尔曼滤波对线性运动进行滤波外推, 如果目标运动是非线性的, 需要采用扩展卡尔曼滤波器(EKF)^{[16][17]}或不敏卡尔曼滤波器(UKF)^[18]; 当跟踪强机动目标时, 一般采用交互式多模型算法和 Jerk 模型算法^[19]等。

如图 2.1 所示, 假设多目标跟踪是一个递推的过程, 并且在开始扫描期间各个目标的航迹已经形成。来自传感器的回波数据首先被用于更新已经建立的目标航迹, 使用跟踪波门粗略的确定量测/航迹是否合理; 再采用数据关联算法, 确定最合理的量测/航迹配对; 最后, 对目标进行滤波与预测, 估计出各个目标航迹的真实状态。在跟踪空间中, 那些不与已经建立的目标航迹相关的量测可能来自与新的目标或者虚警, 由航迹起始算法可以鉴别真伪, 并建立起相应的目标航迹档案; 如果目标已经逃离雷达威力范围或者被摧毁, 由航迹终结算法可以删除该目标航迹, 以减少不必要的计算开销。最后, 在下一时刻的量测数据来临之前, 由接收正确回波的概率与目标的预测位置确定下一时刻关联区域的大小与中心, 开始下一时刻的递推循环。

2.2 目标运动模型

要实现对目标的精确跟踪, 关键是从量测数据中提取出有用的目标状态信息。一个好的目标运动模型有助于信息的提取, 因此大多数的跟踪算法是基于模型的。目标运动模型描述了目标的运动状态随时间的变化过程, 它用来表示目标某一时刻的状态变量与其前一时刻状态变量之间的函数关系。

2.2.1 CA 与 CV 模型

如果目标做匀速直线运动^[20], 其运动状态可用匀速(CV)运动模型表示。该模型中用 $X=[x \quad \dot{x}]^T$ 表示目标运动的状态, 其中的 x 和 \dot{x} 分别是目标的位置分量和速度分量。目标状态方程为:

$$X(k+1) = \Phi X(k) + GW(k) \quad (2-1)$$

其中

$$\Phi = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}, G = \begin{bmatrix} T^2/2 \\ T \end{bmatrix} \quad (2-2)$$

$W(k)$ 是均值为零，方差为 σ_w^2 的高斯白噪声， T 为采样间隔。

当目标做匀加速直线运动时，可以采用 CA 模型来表示它的运动状态。该模型中用 $X = [x \ \dot{x} \ \ddot{x}]^T$ 表示目标运动的状态，其中的 x 、 \dot{x} 和 \ddot{x} 分别是目标的位置、速度和加速度分量。目标状态方程为：

$$X(k+1) = \Phi X(k) + GW(k) \quad (2-3)$$

其中，

$$\Phi = \begin{bmatrix} 1 & T & T^2/2 \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix}, G = \begin{bmatrix} T^3/6 \\ T^2/2 \\ T \end{bmatrix} \quad (2-4)$$

CA 和 CV 模型是目标运动模型中最基本，也是被采用最多的模型，是其他模型的基础。对于匀速、匀加速直线运动或者近似匀速、匀加速的运动，以上模型均能达到良好的跟踪精度。当目标发生机动时，可以用过程噪声表示目标的加速度，可以通过调整 $W(k)$ 的方差近似目标的机动。对于跟踪系统，目标的机动是未知的，显然，如何更加精确的描述目标的机动需要采用更加精确的运动模型。

2.2.2 时间相关模型

Singer 提出的时间相关（Singer）模型假设机动加速度 $a(t)$ 服从一阶时间相关过程，对机动加速度 $a(t)$ 的时间相关函数为指数衰减形式：

$$R_a(\tau) = E[a(t)a(t+\tau)] = \sigma_a^2 e^{-\alpha|\tau|} \quad (2-5)$$

式中 σ_a^2 、 α 为在区间 $(t, t+\tau)$ 内决定目标机动特性的待定参数。 σ_a^2 是目标加速度方差， α 是机动频率。通常 α 的经验取值范围是：大气扰动 $\alpha=1$ ，转弯机动 $\alpha=1/60$ ，逃避机动 $\alpha=1/20$ ，其确切值要通过实时测量才能获取。该模型假定机动加速度的概率密度函数近似服从均匀分布，最大机动加速度 $\pm a_{\max}$ 出现概率设定为 P_{\max} ，不出现加速度的概率为 P_0 ，则方差 σ_a^2 为：

$$\sigma_a^2 = \frac{A_{\max}^2 [1 + 4P_{\max} - P_0]}{3} \quad (2-6)$$

$a(t)$ 用输入为白噪声的一阶时间相关模型表示：

$$\dot{a}(t) = -\alpha a(t) + \omega(t) \quad (2-7)$$

式中, $\omega(t)$ 是均值为零、方差为 $2\alpha\sigma_a^2$ 的高斯白噪声。相应的离散时间方程为:

$$a(k+1) = \beta a(k) + \omega(k) \quad (2-8)$$

其中 $\beta = e^{-\alpha T}$, $\omega(k)$ 是均值为零、方差为 $\sigma^2(1-\beta^2)$ 白噪声序列。因此, 其状态转移方程为

$$X(k+1) = \Phi X(k) + W(k) \quad (2-9)$$

$$\Phi = \begin{bmatrix} 1 & T & (-1+\alpha T + e^{-\alpha T})/\alpha^2 \\ 0 & 1 & (1-e^{-\alpha T})/\alpha \\ 0 & 0 & e^{-\alpha T} \end{bmatrix} \quad (2-10)$$

噪声 $W(k)$ 的协方差矩阵满足:

$$Q(k) = E(W(k)W(k)^T) = 2\alpha\sigma_a^2[q_{ij}]_{3 \times 3} \quad (2-11)$$

其中, q_{ij} 的具体取值方法请参考文献[21]。

与 CA、CV 模型相比, Singer 模型使用有色白噪声而不是用白噪声描述加速度, 能更确切的描述目标的机动, 但是其跟踪性能决定于参数 σ_a^2 、 a , 且计算量较大。因此, 国内外学者对 Singer 模型提出了不少改进方案。周宏仁教授认为, 当目标正以某一加速度进行机动时, 下一时刻的加速度取值只能在“当前”加速度的邻域内, 由此提出了当前统计模型。当前统计模型实际上是一个具有自适应非零均值加速度的 Singer 模型, 与 Singer 模型相比, 该模型采用修正的瑞利分布表征机动加速度的特性, 能更真实地反映目标机动范围和强度的变化, 具有响应速度快, 跟踪精度高的优点, 适用于跟踪机动性较强的目标。

2.2.3 转弯模型

在空中交通管制中^[20], 转弯运动是一种比较常见的运动, 通常也被称为联动式转弯运动 (CT)。其运动特点是目标的速度和角速度大小保持不变, 但速度方向时刻发生变化。由于量测误差的存在, 目标实际的转弯运动并不是标准的联动式转弯, 需要用一个高斯噪声来补偿模型的误差。因此, 目标的转弯运动模型可描述为:

$$X(k+1) = \begin{bmatrix} 1 & \frac{\sin \omega T}{\omega} & 0 & -\frac{1-\cos \omega T}{\omega} & 0 \\ 0 & \cos \omega T & 0 & -\sin \omega T & 0 \\ 0 & \frac{1-\cos \omega T}{\omega} & 1 & \frac{\sin \omega T}{\omega} & 0 \\ 0 & \sin \omega T & 0 & \cos \omega T & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} X(k) + \begin{bmatrix} \frac{T^2}{2} & 0 & 0 \\ T & 0 & 0 \\ 0 & \frac{T^2}{2} & 0 \\ 0 & T & 0 \\ 0 & 0 & T \end{bmatrix} W(k) \quad (2-12)$$

其中, ω 为转弯速率, 目标的状态向量定义为 $X(k) = (x_k, \dot{x}_k, y_k, \dot{y}_k, \omega)^T$, 量测噪声 $W(k)$ 是均值为零, 方差为 Q_k 的高斯白噪声。

当目标转弯速率已知，转弯模型可以很好地模拟目标的转弯机动，从而实现对转弯机动目标的有效跟踪。在 CT 模型中， $w < 0$ 表示目标做顺时针的转弯运动， $w > 0$ 表示目标做逆时针的转弯运动。

2.3 数据关联算法

数据关联是多目标跟踪技术中最核心、最困难的部分，也是本文研究的重点。在杂波环境下，一个目标的跟踪波门中的量测数据可能不止一个，这些量测数据可能来自于该目标，可能来自于其它目标，也可能源自于杂波。由于量测的不确定性，数据关联可以描述为：将有效量测与已知航迹进行比较，并确定可能的航迹与有效回波配对的过程。

2.3.1 最近邻域法

设置跟踪波门，落入跟踪波门中的量测作为候选回波，即目标的量测值 $z_i(k)$ 是否满足：

$$[z_i(k) - \hat{z}(k|k-1)]^T S^{-1}(k) [z_i(k) - \hat{z}(k|k-1)] \leq r \quad (2-13)$$

其中， $\hat{z}(k|k-1)$ 是跟踪波门的中心。如果波门中只有一个量测，则该量测值直接被用于航迹的更新；如果有一个以上的候选回波，则选取统计距离最小的候选回波用于航迹的更新。其中， $z_i(k)$ 对应的统计距离为：

$$d^2(z_i(k)) = [z_i(k) - \hat{z}(k|k-1)]^T S^{-1}(k) [z_i(k) - \hat{z}(k|k-1)] \quad (2-14)$$

最近邻域算法的优点是计算量小，易于实现，适用于低杂波环境的稀疏目标跟踪，密集杂波环境下或目标比较密集时，往往容易误跟、丢失目标。

2.3.2 概率数据关联算法

与最近邻域法不同的是，概率数据关联算法认为落入跟踪波门中的所有量测都可能来自于目标，计算各个有效回波的概率，利用这些概率对各个回波进行加权，有效回波的加权和形成等效回波，这就是概率数据关联算法的主要思想。

假设目标运动的状态方程为：

$$x(k+1) = F(k)x(k) + G(k)w(k) \quad (2-15)$$

观测方程为：

$$z(k) = H(k)x(k) + v(k) \quad (2-16)$$

其中， $x(k)$ 为状态矢量， $z(k)$ 为观测矢量。 $F(k)$ 和 $H(k)$ 分别为状态和观测转移矩阵， $w(k)$ 和 $v(k)$ 分别是相互独立、均值为 0，协方差分别为 Q 和 R 的高斯噪声，

$$E[w(k)(w(j))^T] = Q(k)\delta_{kj} \quad (2-17)$$

$$E[v(k)(v(j))^T] = R(k)\delta_{kj} \quad (2-18)$$

其中, δ_{kj} 为冲激函数。

k 时刻, 有效回波集合为 $Z(k) = \{z_i(k)\}_{i=1}^{m_k}$, $Z^k = \{Z(j)\}_{j=1}^k$ 表示到 k 时刻有效回波的集合, m_k 表示 k 时刻有效回波的个数。在 k 时刻, 任一量测 $z_i(k)$ 满足式(2-13)即被认为是有效回波。将数据关联算法和卡尔曼滤波器结合起来, PDAF 的更新滤波方程为:

$$\hat{x}(k|k-1) = F(k)\hat{x}(k-1|k-1) \quad (2-19)$$

$$P(k|k-1) = F(k)P(k-1|k-1)F(k)^T + G(k)QG(k)^T \quad (2-20)$$

$$\hat{z}(k|k-1) = H(k)\hat{x}(k|k-1) \quad (2-21)$$

$$S(k) = H(k)P(k|k-1)H(k)^T + R(k) \quad (2-22)$$

$$K(k) = P(k|k-1)H(k)^T S(k)^{-1} \quad (2-23)$$

$$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)v(k) \quad (2-24)$$

$$v(k) = \sum_{i=1}^{m_k} \beta_i(k)v_i(k) \quad (2-25)$$

$$v_i(k) = z_i(k) - \hat{z}(k|k-1) \quad (2-26)$$

$$P(k|k) = \beta_0(k)P(k|k-1) + (1-\beta_0(k))P^c(k|k) + \tilde{P}(k) \quad (2-27)$$

式中

$$P^c(k|k) = [I - K(k)H(k)]P(k|k-1) \quad (2-28)$$

$$\tilde{P}(k) = K(k) \left[\sum_{i=1}^{m_k} \beta_i(k)v_i(k)v_i'(k) - v(k)v'(k) \right] K'(k) \quad (2-29)$$

$\beta_i(k)$ 表示量测 $z_i(k)$ 源于目标的关联概率, $\beta_0(k)$ 表示没有量测源于目标的或量测是虚警的概率。 $\beta_i(k)$ 的详细推导可以参见文献[22], 这里简单描述如下:

定义事件

$$\theta_i(k) = \{z_i(k) \text{ 是源于目标的量测}\}, \quad i=1, 2, \dots, m_k$$

$$\theta_0(k) \overset{\Delta}{=} \{\text{在 } k \text{ 时刻没有源于目标的量测}\}$$

以量测集合 Z^k 为条件, 第 i 个量测 $z_i(k)$ 源于目标的条件概率为

$$\beta_i(k) = \Pr\{\theta_i(k) | Z^k\} \quad (2-30)$$

由于这些事件是互斥且穷举的, 所以关联概率 $\beta_i(k)$ 必须满足以下约束:

$$\sum_{i=0}^{m_k} \beta_i(k) = 1, \quad 0 \leq \beta_i(k) \leq 1 \quad (2-31)$$

将量测集合 Z^k 分为累积数据 Z^{k-1} 和最新数据 $Z(k)$, 即

$$\begin{aligned} \beta_i(k) &= P_r\{\theta_i(k) | Z^k\} \\ &= \frac{1}{c_k} p[Z(k) | \theta_i(k), m_k, Z^{k-1}] \times P\{\theta_i(k) | m_k, Z^{k-1}\} \end{aligned} \quad (2-32)$$

$i = 0, 1, \dots, m_k$

其中, c_k 是归一化常数。

使用参数模型, PDAF 的关联概率可用下式计算

$$\begin{aligned} \beta_0(k) &= \frac{b}{b + \sum_{i=1}^{m_k} e_i} \\ \beta_i(k) &= \frac{e_i}{b + \sum_{i=1}^{m_k} e_i} \quad i = 1, \dots, m_k \end{aligned} \quad (2-33)$$

其中

$$b = \lambda |2\pi S(k)|^{\frac{1}{2}} \frac{1 - P_D P_G}{P_D} = |2\pi|^{\frac{1}{2}} \gamma^{\frac{-n_z}{2}} \frac{\lambda V_k}{c_{n_z}} \frac{1 - P_D P_G}{P_D} \quad (2-34)$$

$$e_i = \exp\left[-v_i(k)^T(k) S^{-1}(k) v_i(k) / 2\right] \quad (2-35)$$

V_k 表示椭圆有效区域的体积, P_D 表示检测到真实目标的概率, P_G 表示目标真实观测落入 m 维椭圆有效区域的概率, λ 为杂波密度, n_z 为量测值 $z_i(k)$ 的维数。若式 (2-35) 的 λV_k 用 m_k 代替, 则可获得非参数模型的关联概率 $\beta_0(k)$ 和 $\beta_i(k)$ 。

在 PDAF 中, 杂波密度是一个很重要的参数, 直接关系到关联概率的计算。然而, 这一参数在实际情况中很难获得。文献[23]提出了一种修正的概率数据关联算法, 能够较为实用的解决杂波密度的实时估计问题。

由于 PDAF 的推导是基于关联区域中仅有一个目标的有效回波存在的假设, 因此该算法仅适用于单目标或稀疏多目标的跟踪, 在密集目标环境下, 跟踪性能会大大下降。

2.3.3 联合概率数据互联算法

联合概率数据关联算法是在 PDA 算法的基础上提出来的, 它综合考虑了所有落入跟踪波门内的回波, 认为公共回波并非只源于一个目标, 可能分属于不同的目标。因此, JPDA 算法适用于杂波环境下的多目标跟踪。

在密集杂波环境下, 目标 t 的状态方程为

$$X^t(k+1) = FX^t(k) + G(k)W^t(k), t=1,2,\dots,T \quad (2-36)$$

量测方程为

$$Z(k) = \begin{cases} HX^t(k) + v(k) & \text{if measurement is from target } t \\ u(k) & \text{if measurement is not from target } t \end{cases} \quad (2-37)$$

当有回波落入不同目标跟踪波门的重叠区域时, 需要综合考虑各个回波的目标来源。为了表示有效回波与各目标跟踪门之间复杂的关系, Bar-Shalom 引入了确认矩阵的概念。确认矩阵被定义为:

$$\Omega = \left\{ \begin{matrix} \overbrace{\begin{bmatrix} w_{10} & \cdots & w_{1T} \\ \vdots & \cdots & \vdots \\ w_{m_k 0} & \cdots & w_{m_k T} \end{bmatrix}}^T \end{matrix} \right\}_j \quad (2-38)$$

式中, $w_{jt} = 1$ 表示量测 $j (j=1,2,\dots,m_k)$ 在目标 t 的跟踪波门中, $w_{jt} = 0$ 表示量测 j 没有落入目标 t 的跟踪波门中。矩阵第一列元素 $w_{j0} = 1$, 因为每个量测都有可能来自于虚警或杂波。

当得到有效量测与目标或虚警之间的确认矩阵后, 需要对确认矩阵进行拆分, 得到所有表示互联事件的互联矩阵。确认矩阵的拆分需要依据以下基本的假设:

- 1) 每一个回波有唯一的来源, 即任一回波不来自某目标, 则来自于杂波。
- 2) 对于某个确定的目标, 只有一个回波以其为源。如果某个目标可能与和多个回波匹配, 将取其中一个为真, 其余为假。

即确认矩阵的拆分须遵循以下两个原则:

- 1) 在确认矩阵的每一行, 选出唯一一个 1, 作为互联矩阵在该行的非零元素。
- 2) 在互联矩阵中, 除第一列外, 每列最多有一个非零元素。

设 $\theta_{jt}(k)$ 表示量测 j 源于目标 t 的事件, 而事件 $\theta_{j0}(k)$ 表示量测 j 源于杂波或者虚警。第 j 个量测与目标 t 互联概率定义为:

$$\beta_{jt}(k) = \Pr\{\theta_{jt}(k) | Z^k\}, \quad j = 0, 1, \dots, m_k, t = 0, 1, \dots, T \quad (2-39)$$

且满足约束条件 $\sum_{j=0}^{m_k} \beta_{jt}(k) = 1$ 。

k 时刻, 目标 t 的状态估计为

$$\hat{X}^t(k|k) = E[X^t(k)|Z^k] = \sum_{j=0}^{m_k} \beta_{jt}(k) \hat{X}_j^t(k|k) \quad (2-40)$$

式中 $\hat{X}_j^t(k|k) = E[X^t(k)|\theta_{jt}(k), Z^k]$, 表示 k 时刻用第 j 个回波对目标 t 进行卡尔曼滤波得到的目标状态, $\hat{X}_0^t(k|k)$ 表示 k 时刻没有回波源于目标的情况, 这时用预测值 $\hat{X}^t(k|k-1)$ 来代替。即目标 t 的状态估计方程可写为

$$\hat{X}^t(k|k) = \hat{X}^t(k|k-1)\beta_{0t}(k) + \sum_{j=1}^{m_k} \beta_{jt}(k) \hat{X}_j^t(k|k) \quad (2-41)$$

第 j 个回波与目标 t 之间的互联概率可用下式求得:

$$\beta_{jt}(k) = \Pr\{\theta_{jt}(k)|Z^k\} = \Pr\left\{\bigcup_{i=1}^{n_k} \theta_{jt}^i(k)|Z^k\right\} = \sum_{i=1}^{n_k} w_{jt}^i[\theta_i(k)] \Pr\{\theta_i(k)|Z^k\} \quad (2-42)$$

式中, $\theta_{jt}^i(k)$ 表示量测 j 在第 i 个联合事件中来源于目标 t 的事件, $\theta_i(k)$ 表示第 i 个可行互联事件, n_k 表示可行互联事件的个数, 而

$$w_{jt}^i(\theta_i(k)) = \begin{cases} 1, & \text{if } \theta_{jt}^i(k) \subset \theta_i(k) \\ 0, & \text{other} \end{cases} \quad (2-43)$$

表示在第 i 个可行互联事件中, 量测 j 是否来源于目标 t , 量测 j 来源于目标 t 则为1, 否则为0。

在 k 时刻, 联合事件 $\theta_i(k)$ 的条件概率 $\Pr\{\theta_i(k)|Z^k\}$ 的详细推导过程请参考文献[2]。JPDA滤波器有两种形式, 参数的JPDA滤波器使用泊松分布,

$$\Pr\{\theta_i(k)|Z^k\} = \frac{\lambda^{\phi[\theta_i(k)]}}{c'} \prod_{j=1}^{m_k} N_{t_j}[Z_j(k)]^{\tau_j[\theta_i(k)]} \prod_{t=1}^T (P_D^t)^{\delta_t[\theta_i(k)]} (1-P_D^t)^{1-\delta_t[\theta_i(k)]} \quad (2-44)$$

非参数的JPDA滤波器使用均匀分布,

$$\Pr\{\theta_i(k)|Z^k\} = \frac{1}{c''} \frac{\phi[\theta_i(k)]!}{V^{\phi[\theta_i(k)]}} \prod_{j=1}^{m_k} N_{t_j}[Z_j(k)]^{\tau_j[\theta_i(k)]} \prod_{t=1}^T (P_D^t)^{\delta_t[\theta_i(k)]} (1-P_D^t)^{1-\delta_t[\theta_i(k)]} \quad (2-45)$$

在上面的式中, λ 为虚假量测的空间密度, c' 、 c'' 为归一化常数, δ_t 为目标检测指示器, 如果目标 t 在联合事件 $\theta_i(k)$ 中与量测关联, 则 $\delta_t[\theta_i(k)]$ 的值等于1, 反之为零。 Φ 是虚假观测事件的个数, P_D^t 表示目标 t 的检测概率, V 表示航迹有效门体积。

目标的协方差阵的更新方程为:

$$P^t(k|k) = P^t(k|k-1) - (1 - \beta_{0t}(k))K^t(k)S^t(k)K^{t'}(k) + \sum_{j=0}^{m_k} \beta_{jt}(k) \left[\hat{X}_j^t(k|k) \left(\hat{X}_j^t(k|k) \right)' - \hat{X}^t(k|k) \hat{X}^{t'}(k|k) \right] \quad (2-46)$$

式中， $S^t(k)$ 为目标 t 的新息协方差矩阵， $K^t(k)$ 为目标 t 的增益矩阵， $P^t(k|k-1)$ 为预测协方差矩阵，它们的计算公式如下：

$$S^t(k) = H(k)P^t(k|k-1)H^t(k) + R(k), t=1, 2, \dots, T \quad (2-47)$$

$$K^t(k) = P^t(k|k-1)H^t(k)(S^t(k))^{-1} \quad (2-48)$$

$$P^t(k|k-1) = FP^t(k|k-1)F' + Q^t(k-1), t=1, 2, \dots, T \quad (2-49)$$

式 (2-39) ~ (2-49) 构成了 JPDA 算法。

2.3.4 其他的经典算法

1. 多假设跟踪

多假设跟踪 (Multiple Hypothesis Tracking MHT) 算法^[24]是 1978 年由 Reid 首先提出的，它以“全邻”最优滤波器和 Bar-Shalom 提出的聚矩阵为基础，主要过程包括：聚的构成、“假设”的产生、每一个假设的概率计算以及假设约简。该算法综合了联合概率数据关联算法和最近邻算法的优点，适用于低检测概率、高虚警率、密集杂波环境下的多目标跟踪；缺点是过于依赖目标与杂波的先验知识，并且该算法的计算量随着目标与杂波个数的增加而呈指数增长。

2. 航迹分裂法

航迹分裂法是 20 世纪 60 年代 Slitter 首先提出的，1975 年由 Smith 和 Buechler 进一步研究发展起来的一种以似然函数检测为基础的数据关联算法。基本原理是在航迹已经起始的前提下，将落入相关门中的候选回波均作为目标回波，每个目标当前时刻的跟踪波门中有多少个候选回波，原来的目标航迹就要裂为相应数目的新航迹，然后计算出每条航迹的似然函数，高于某一设定门限的航迹进行保留，否则删除对应航迹。

3. 模糊数学及神经网络

由于环境中噪声的影响以及传感器分辨率的限制，得到的量测数据并不能完全准确的反映目标的真实情况，带有一定程度的模糊性，以及目标运动模型的不确定性，不少学者将模糊数学理论引入多目标跟踪。现在国内外的研究工作主要

集中在以下三个方面^[25]：模糊聚类的应用^[26-30]，模糊数学和神经网络的结合，模糊推理技术的应用。文献[31]提出了一种模糊数据关联方法，成功地将模糊 C 均值聚类算法用于解决数据关联，降低了计算的复杂度，减少了计算量。Mourad Oussalah^[26]将模糊聚类与 PDA、JPDA 结合，提出了适合于单目标跟踪的混合模糊概率数据关联滤波算法和适合于多目标跟踪的混合模糊联合概率数据关联滤波算法。该方法引入了噪声聚类的思想，把噪声认为第 $m+1$ 个虚假观测，给出了一种新的聚类方法。通过对模糊隶属度的重建，给出了一种新的关联概率计算方法，实现了对目标的跟踪。

针对联合概率数据关联算法的计算量随着目标与有效回波数目的增加而出现的组合爆炸现象，敬忠良对神经网络在目标跟踪与数据关联中的应用进行研究，利用增益模拟算法和波尔兹曼随机神经网络对 JPDA 算法进行了改进，抑制了算法的计算量，其专著《神经网络跟踪理论及应用》，对神经网络在多目标跟踪与数据关联方面的应用进行了全面、系统的研究与论述。

4. 多扫描分配算法

由于数据关联过程存在的不确定性，传统的基于单次扫描的数据关联算法可能得不到正确的结果，使用多次扫描的结果进行数据关联可能会提高跟踪性能。基于多扫描的数据关联算法的核心是计算似然函数，该似然函数可以用于航迹起始，也可用于航迹的维持。Morefiel 提出的整数规划算法是最早的多扫描分配算法，该算法计算每个联合事件的后验概率，选择概率最大的联合事件关联，但该算法在组合优化中是一个 NP-hard 问题。

多维分配算法也是近几年多扫描分配算法的研究方向之一，如广义 S 维分配算法。多维分配算法既可以用于航迹起始，也可以用于航迹维持，但是其计算量一般都随着问题规模的增大呈指数增长，目前一般采用拉格朗日松弛算法解决这一问题。

5. 粒子滤波

粒子滤波是指通过寻找一组加权随机样本（粒子）来近似表征后验密度函数，以加权样本的求和运算代替后验密度函数的积分运算，从而获得状态的最小方差估计的过程。粒子滤波算法摆脱了非线性滤波时随机量需要满足高斯分布的制约条件，并一定程度上缓解了粒子数样本匮乏的问题，该算法在多目标跟踪中的应用与研究成为近几年来国际上研究的一个热点。Rickard Karlsson 将联合概率数据关联算法和粒子滤波相结合，提出了一种蒙特卡罗联合概率数据关联方法（MC-JPDAF）。虽然粒子滤波能够有效地解决非高斯、非线性系统的滤波问题，

但是算法在实时性以及状态初始概率的选取上依然存在问题。粒子数越多，滤波效果越好，但计算量随着粒子数的增加而呈级数增长。因此，在选择粒子数时，需要对滤波性能和计算量之间折衷考虑。

6. 概率假设密度滤波

对于对于数目确定的多目标跟踪，传统的基于数据关联的多目标跟踪方法能够很好的跟踪目标，但是当目标的数目未知或随时间变化时，传统的多目标跟踪算法将很难跟踪目标，基于随机有限集（RFS）统计理论的概率假设密度（PHD）滤波能够很好的解决这个问题。基于随机集的多目标跟踪方法最早是由 Mahler^[32]提出的，该类算法通过将观测集合与多目标状态表示为随机有限集进行整体处理，将检测、分类和跟踪融为一体，避免了数据关联。PHD 滤波采用多目标随机集合后验概率密度的一阶统计量来代替多目标后验概率密度函数，以此递推估计目标数和目标状态。但是要得到数学上严格意义的 PHD 滤波器非常困难，B.N.Vo 及其研究小组提出了针对被动传感器的高斯粒子 PHD 算法^[33]，以及能为 PHD 滤波提供闭合解的高斯混合 PHD 算法。同时，Maher 和 Vo 的团队继 PHD 之后又提出了带势估计的概率假设密度（CPHD）滤波^[34]以及多目标多贝努利（MeMBer）滤波。目前，一些基于随机集理论的多目标跟踪算法已经开始被用于声纳、红外等探测系统中。

2.4 交互式多模型算法

使用基于单模型的跟踪算法对机动目标进行跟踪时，由于运动模型需要先验地假定而不能很好的匹配目标的机动运动，导致跟踪性能下降。特别是机动性强时，目标运动模式的结构、参数变化很大，导致单模型的算法很难辨别机动参数，从而造成运动模型的不准确，导致算法性能的下降。针对这个问题，Bar-Shalom^[2]和 Blom 在广义伪 Bayes 算法基础上，提出了交互式多模型（IMM）算法。交互式多模型算法^[35]中，多种运动模型并行工作，用模型的后验概率对滤波器的输入、输出均进行加权计算，这不仅使得算法中的在线模型尽可能接近目标的实际运动状况，而且可以保障所有滤波器的输入与系统的实际状况相吻合。

交互式多模型算法^[35]包含多个并行的滤波器（各自对应着相应的运动模型）、一个模型概率估计器、一个交互式作用器（滤波器的输入端）和一个估计混合器（滤波器的输出端），多个模型通过交互作用来跟踪机动目标，包含 N 个模型的 IMM 算法如图 2.2 所示。

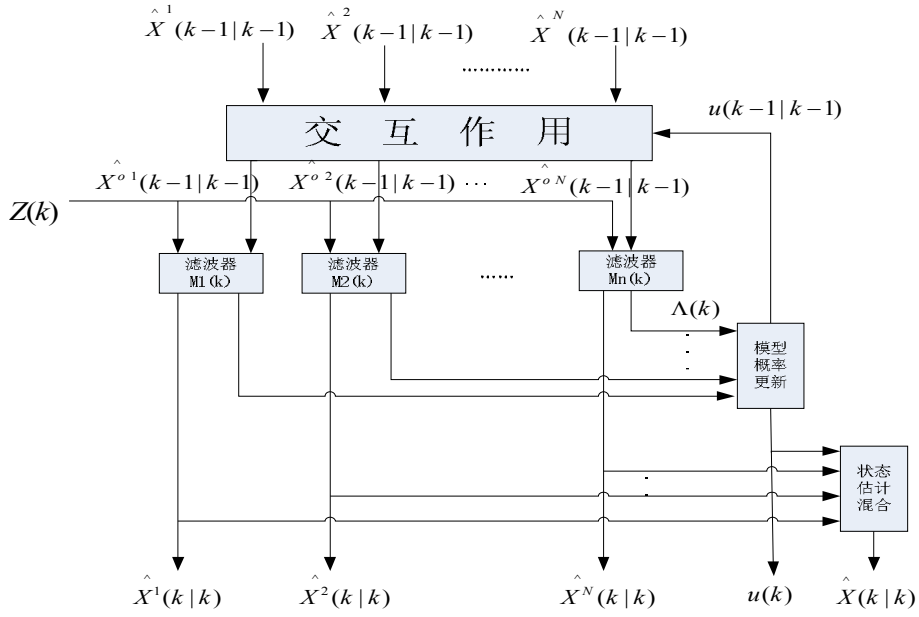


图 2.2 交互式多模型算法原理图

图中， $\hat{X}(k|k)$ 为基于 N 个模型的状态估计， $\hat{X}^j(k|k)(j=1,2,\dots,N)$ 为模型 j 的状态估计。 $\Lambda(k)$ 为模型可能性向量， $u(k)$ 为模型概率向量。 $\hat{X}^j(k-1|k-1)$ ，为 $k-1$ 时刻第 j 个滤波器的输出， $\hat{X}^{oj}(k-1|k-1)$ 为 $\hat{X}^j(k-1|k-1)$ 交互作用的结果，它作为 k 时刻第 j 个滤波器的输入， $Z(k)$ 为 k 时刻的量测。

2.4.1 交互式多模型算法

IMM 算法中，模型概率的切换是在 Markov 链下进行的，马尔可夫链的状态转移矩阵为

$$P_{t_{ij}} = \begin{bmatrix} p_{t_{11}} & \cdots & p_{t_{1r}} \\ \vdots & \ddots & \vdots \\ p_{t_{r1}} & \cdots & p_{t_{NN}} \end{bmatrix}, \text{ 其中, } p_{t_{ij}} \text{ 表示从模型 } i \text{ 转移到模型 } j \text{ 的转移概率。}$$

假设有 N 个模型

$$X(k+1) = F_j X(k) + G_j W_j(k), j=1, \dots, N \quad (2-50)$$

其中， $W_j(k)$ 是均值为零、协方差为 Q_j 的白噪声序列。IMM 算法是个递推过程，具有 N 个模型的 IMM 算法从 $k-1$ 时刻到 k 时刻的递推流程如下：

步骤 1: 输入交互

混合概率

$$\mu_{i|j}(k-1|k-1) = p_{ij}\mu_i(k-1)/c_j \quad (2-51)$$

标准化因子

$$c_j = \sum_{i=1}^N p_{ij}\mu_i(k-1) \quad (2-52)$$

模型 j 的混合初始状态为

$$\hat{X}^{oj}(k-1|k-1) = \sum_{i=1}^N X_i(k-1|k-1)\mu_{i|j}(k-1|k-1) \quad j=1,2,\dots,N \quad (2-53)$$

相应的状态协方差为

$$P^{oj}(k-1|k-1) = \sum_{i=1}^N \mu_{i|j}(k-1|k-1) \left\{ P^i(k-1|k-1) + \left[X^i(k-1|k-1) - \hat{X}^{oj}(k-1|k-1) \right] \left[X^i(k-1|k-1) - \hat{X}^{oj}(k-1|k-1) \right]^T \right\} \quad (2-54)$$

其中, $\mu_i(k-1)$ 为 $k-1$ 时刻模型 i 的概率, $P^i(k-1|k-1)$ 为相应的状态协方差阵。

步骤 2: 模型修正

对应于模型 $M_j(k)$, 以 $\hat{X}^{oj}(k-1|k-1)$ 、 $P^{oj}(k-1|k-1)$ 以及 $Z(k)$ 为输入进行卡尔曼滤波。

$$\hat{X}^j(k/k-1) = F_j(k|k-1)\hat{X}^{oj}(k-1/k-1) \quad (2-55)$$

$$P_{\hat{X}}^j(k/k-1) = F_j(k|k-1)P_{\hat{X}}^{oj}(k-1/k-1)F_j^T(k|k-1) + G_jQ(k-1)G_j^T \quad (2-56)$$

$$S_j(k) = H(k)P_{\hat{X}}^j(k/k-1)H^T(k) + R(k) \quad (2-57)$$

$$K_j(k) = P_{\hat{X}}^j(k/k-1)H^T(k)S_j(k)^{-1} \quad (2-58)$$

$$\hat{X}^j(k/k) = \hat{X}^j(k/k-1) + K_j(k) \left[Z(k) - H(k)\hat{X}^j(k/k-1) \right] \quad (2-59)$$

$$P_{\hat{X}}^j(k/k) = \left[I - K_j(k)H(k) \right] P_{\hat{X}}^j(k/k-1) \left[I - K_j(k)H(k) \right]^T + K_j(k)R(k)K_j^T(k) \quad (2-60)$$

步骤 3: 模型概率更新

模型 j 在 k 时刻的概率为:

$$\mu_j(k) = \frac{1}{c} \Lambda_j(k) \sum_{i=1}^N p_{ij}\mu_i(k-1) = \frac{1}{c} \Lambda_j(k)c_j \quad (2-61)$$

式中, c 为归一化常数, $c = \sum_{j=1}^N \Lambda_j(k) c_j$, $\Lambda_j(k)$ 为观测 $Z(k)$ 的似然函数

$$\begin{aligned}\Lambda_j(k) &= P\{Z(k) / M_j(k), Z^{k-1}\} \\ &= \exp\left\{-\frac{1}{2} \mathbf{v}_j^T S_j^{-1}(k) \mathbf{v}_j\right\} / \left((2\pi)^{n/2} |S_j(k)|^{1/2}\right)\end{aligned}\quad (2-62)$$

其中 $\mathbf{v}_j(k) = Z(k) - H(k) \hat{X}^j(k/k-1)$ 。

步骤 4: 模型输出

设 $\hat{X}(k/k)$, $P(k/k)$ 分别为 k 时刻的交互式输出, 则有

$$\hat{X}(k/k) = \sum_{j=1}^N \hat{X}^j(k/k) \mu_j(k) \quad (2-63)$$

$$P(k/k) = \sum_{j=1}^N \mu_j(k) \left\{ P^j(k/k) + \left[\hat{X}^j(k/k) - \hat{X}(k/k) \right] \left[\hat{X}^j(k/k) - \hat{X}(k/k) \right]^T \right\} \quad (2-64)$$

IMM 算法对量测信息的利用不仅反映在滤波估计中, 而且反映在模型概率中, 通过模型概率的变化达到自适应调整模型的作用; 依据应用环境的不同, 滤波模块可采用各种线性和非线性滤波算法, 因此对强机动目标有良好的跟踪效果。IMM 算法中, 通常用几个经典的运动模型来近似描述目标的运动特性, 如 CA 模型、CV 模型、当前统计模型和 CT 模型。

但是 IMM 算法存在以下问题:

- 1) 如何选择保持最佳跟踪性能的离散机动水平, IMM 算法是以较大的计算量换取机动性能的提高;
- 2) 增加模型可以提高跟踪精度但会增加计算量, 且引入模型竞争使性能降;
- 3) 由于无法事先获取模型之间的准确转换概率, 事先确定模型之间的转换概率导致 IMM 算法的使用和跟踪精度的受限。

针对以上问题, 国内外很多学者对 IMM 算法进行了改进。Li. X.R 和 Kirubarajan. T^[36] 直接对交互式模型改进, 提出变结构交互式多模型算法(VSMM), 先建立一个总模型集, 在跟踪过程中根据目标的模式状态在总模型集合中选择匹配的模式组成子集; Munir.A 和 Atherton.D.P 在 1994 年首先提出一种自适应交互式多模型算法(AIMM), 它利用模式的状态相关性对模型修正使模型与目标模式相匹配, 提高了跟踪性能; 梁彦^[37]在 2001 年提出了一种将参数辨识与 IMM 结合的 AIMM 算法。一般地, 将 IMM 算法与 PDA 算法相结合形成的 IMM-PDA 算法, 在杂波环境下对单个机动目标或稀疏的多个机动目标能够进行良好的跟踪。将 IMM 算法跟

JPDA 算法结合形成的 IMM-JPDA 算法，能够在杂波环境下跟踪多个机动目标，但是其计算量很大，很难满足实时性的要求。

2.4.2 交互式多模型概率数据关联算法

IMM 算法引入多个目标运动模型，对每一个模型的状态估计按照一定的概率加权来实现机动目标的跟踪。杂波环境下，为了跟踪强机动目标，通常使用 IMM 算法与 PDAF 结合形成交互式多模型概率数据关联滤波器 (IMMPDAF)。假设有 N 个模型，算法步骤如下：

步骤 1：输入交互

计算公式同 IMM 算法的步骤 1。

步骤 2：卡尔曼滤波

基于模型 M_j ，以 $\hat{X}^{oj}(k-1/k-1)$ 、 $P^{oj}(k-1/k-1)$ 为输入，应用 PDA 算法计算基于 M_j 的状态估计 $\hat{X}^j(k/k)$ 和协方差 $P_{\hat{X}}^j(k/k)$ 。

$$\hat{X}^j(k/k-1) = F_j(k|k-1)\hat{X}^{oj}(k-1/k-1) \quad (2-65)$$

$$P_{\hat{X}}^j(k/k-1) = F_j(k|k-1)P_{\hat{X}}^{oj}(k-1/k-1)F_j^T(k|k-1) + G_jQ(k-1)G_j^T \quad (2-66)$$

$$\hat{X}^j(k/k) = \hat{X}^j(k/k-1) + K_j(k)\tilde{z}_j(k|k-1) \quad (2-67)$$

$$P_{\hat{X}}^j(k/k) = P_{\hat{X}}^j(k/k-1) - K_j(k)S_j(k)(K_j(k))^T \quad (2-68)$$

式中， $K_j(k)$ 、 $\tilde{z}_j(k|k-1)$ 以及 $S_j(k)$ 分别是基于模型 M_j 得到的卡尔曼增益、组合新息、以及新息协方差阵。

步骤 3：模型概率更新

似然函数

$$\begin{aligned} \Lambda_j(k) &= V_j^{-m_k}(k)(1-P_D) + V_j^{1-m_k}(k)\frac{P_D}{m_k}\sum_{m=1}^{m_k}e_j^m(k) \\ &= \frac{P_D}{m_k}V_j^{1-m_k}(k)\left(b + \sum_{m=1}^{m_k}e_j^m(k)\right) \quad j=1,2,\dots,N \end{aligned} \quad (2-69)$$

式中， $e_j^m(k) = \exp\left\{-\frac{1}{2}\left(z_m(k) - \hat{z}(k|k-1)\right)^T S_j^{-1}(k)\left(z_m(k) - \hat{z}(k|k-1)\right)\right\}$ ， $V_j(k)$ 是第

j 个子滤波器按量测预测值及协方差计算出的波门体积， $z_m(k)$ 为 k 时刻第 m 个有

效回波， b 的计算请参考式 (2-35)。

模型 M_j 在 k 时刻的模型概率

$$\mu_j(k) = \frac{\Lambda_j(k) \sum_{i=1}^N p_{ij} \mu_i(k-1)}{\sum_{j=1}^N \sum_{i=1}^N \Lambda_j(k) p_{ij} \mu_i(k-1)} \quad j=1, \dots, N \quad (2-70)$$

步骤 4: 模型输出

利用上述结果得到状态估计值与估计误差的协方差阵

$$\hat{X}(k/k) = \sum_{j=1}^N \hat{X}^j(k/k) \mu_j(k) \quad (2-71)$$

$$P(k/k) = \sum_{j=1}^N \mu_j(k) \left\{ P^j(k/k) + \left[\hat{X}^j(k/k) - \hat{X}(k/k) \right] \left[\hat{X}^j(k/k) - \hat{X}(k/k) \right]^T \right\} \quad (2-72)$$

2.5 仿真结果及分析

2.5.1 概率数据互联算法

目标做匀速直线运动，起始状态为 $x_0 = [1\text{km} \ 0.5\text{km/s} \ 1\text{km} \ 0.1\text{km/s}]$ ，过程噪声分量 $Q_{ii} = 4 \times 10^{-4} \text{km}^2$ ，传感器量测噪声为零均值的高斯白噪声，其标准差 $\sqrt{R_{ii}} = 0.15 \text{km}$ ，探测概率 $P_D = 0.9999$ ，门概率为 $P_G = 0.99$ ，采用椭圆跟踪门规则，阈值 $\gamma = 9.21$ ，采样间隔为 $T = 1 \text{s}$ ，进行 100 次 Monte Carlo 仿真，步数为 50，杂波的数目服从参数为 $\lambda = 1$ 个/ km^2 的泊松分布，在以目标预测值为中心的椭圆区域内服从均匀分布。PDAF 与最近邻算法 (NNKF) 仿真结果如图 2.3-2.7 所示：




图 2.3 NNKF 跟踪效果图 1




图 2.4 NNKF 跟踪效果图 2




图 2.5 PDAF 跟踪效果图




图 2.6 两种算法位置 RMS 误差对比 1

图 2.3 是 NNKF 成功跟踪目标时的效果图, 图 2.4 是 NNKF 丢失目标时的效果图, 图 2.6 是 PDAF 与 NNKF 成功跟踪时的最小均方误差的对比, 图 2.7 是 PDAF 与丢失目标时的 NNKF 的 RMS 对比。由仿真结果可知, 杂波环境下, 与最近邻域法相比, PDAF 有着更优越的跟踪性能。在计算量方面, 完成 100 次 Monte Carlo 仿真, PDAF 需要 1.3139 s, NNKF 需要的 1.0452 s。在密集杂波环境下, 最近邻域法很容易跟丢目标。

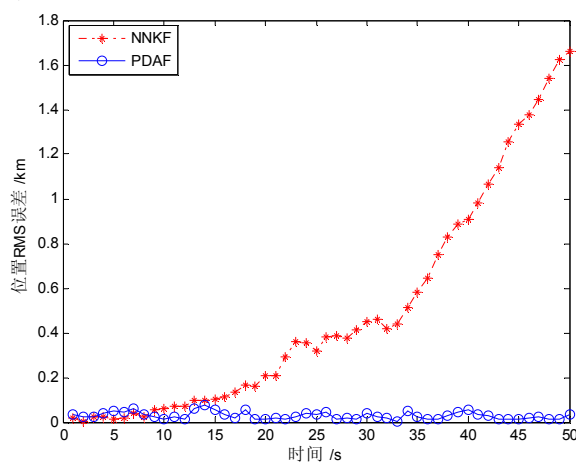


图 2.7 两种算法的位置 RMS 误差对比 2

2.5.2 交互式多模型算法

目标初始状态: $X(0) = [-20000m, 20000m]$, 径向速度 $v=300$ m/s, 运动过程为:
 0~34 s, 目标做匀速直线运动;
 35~58 s, 目标做匀速圆周运动, 向心加速度为 $a = 20$ m/s²;
 59~91 s, 目标做匀速直线运动;

雷达量测误差标准差为 200 m, 雷达扫描周期为 $T=2$ s, 模型间的马尔可夫转移概率矩阵初始值为 $P_{t_2} = [0.95 \ 0.05; 0.95 \ 0.05]$, 进行 100 次 Monte Carlo 仿真, 仿

真结果如图 2.8-2.9 所示:

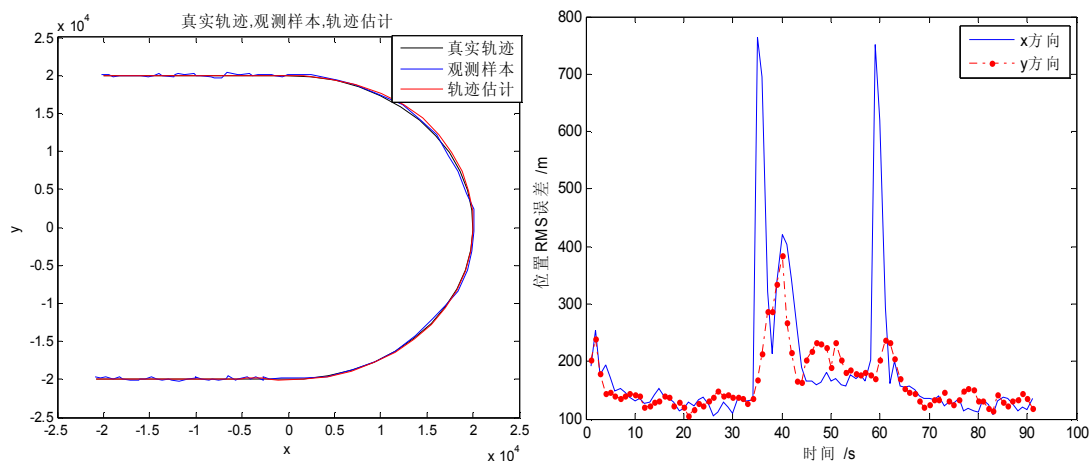


图 2.8 目标的真实轨迹、观测位置、滤波位置 图 2.9 目标的位置 RMS 误差统计

改变目标的向心加速度, 目标运动过程如下:

0~34 s, 目标做匀速直线运动;

35~128 s, 目标做匀速圆周运动, 向心加速度变为 $a = 5 \text{ m/s}^2$;

129~161 s, 目标做匀速直线运动;

其它条件保持不变, 再次进行仿真, 仿真结果如图 2.10-2.11 所示:

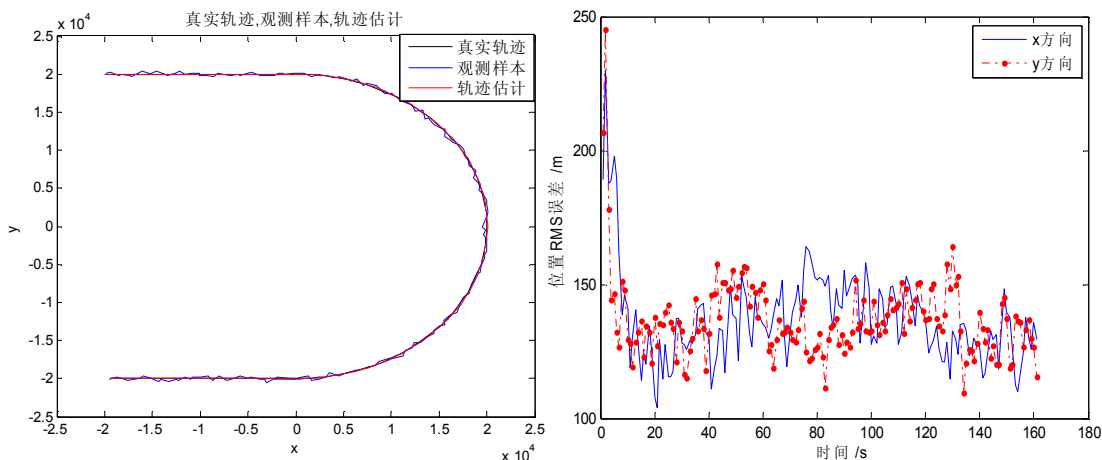


图 2.10 真实轨迹、观测位置、滤波位置 图 2.11 目标位置 RMS 误差统计

由仿真结果可知, 开始时, 滤波误差较大, 随着时间推移, 滤波误差逐渐收敛, 滤波值逐渐逼近真实轨迹。由图 2.9 可知, 在 $t=35 \text{ s}$ 和 59 s 附近, 已经收敛的滤波误差再次变大, 然后又逐渐减小, 说明模型之间的转换会带来较大的误差。

当向心加速度较大时, 由于运动角速度较大, 滤波误差较大; 当向心加速度较小时, 由于运动角速度较小, 滤波误差较小。

当扫描时间较短时, 由于观测数据较少, 滤波精度较低; 当扫描时间变长时, 由于观测数据增多, 滤波精度有所提高。

需要注意的是, IMM 算法的滤波效果受控制模型转化的马尔科夫链的转移概

率矩阵影响较大，与初值的设定也有一定的关系。

由以上的仿真可知，目标机动性强时，IMM 算法能够很好地对目标进行跟踪。

2.5.3 交互式多模型概率数据关联算法

目标初始位置为 $X[0] = (2 \text{ km}, 8 \text{ km}, 1 \text{ km})$ ，目标的运动速度为 0.3 km/s ，采样周期 $T = 1 \text{ s}$ 。目标的运动过程如下：

第一阶段：1~30 s，目标沿与 x 轴呈 60° 的方向做匀速直线运动；

第二阶段：31~50 s，目标做匀速转弯运动，转动角度的大小 $\theta_1 = 120^\circ$ ；

第三阶段：51~70 s，目标沿与 x 轴呈 -60° 的方向做匀速直线运动；

第四阶段：71~95 s，目标做匀速转弯运动，转动角度的大小 $\theta_2 = 120^\circ$ ；

第五阶段：96~100 s，目标沿与 x 轴呈 60° 的方向做匀速直线运动；

门限值 $g = 13.27$ ， $P_d = 1$ ， $P_g = 0.99$ 。杂波在目标真实位置周围服从均匀分布，杂波数目服从 $0 \sim \lambda$ 的均匀分布， $\lambda = 3$ 。仿真中采用 3 个运动模型（一个 CV 模型和两个 CT 模型），各个模型的转移矩阵为：

$$F_1 = \begin{pmatrix} 1 & 0 & 0 & T & 0 & 0 \\ 0 & 1 & 0 & 0 & T & 0 \\ 0 & 0 & 1 & 0 & 0 & T \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix} \quad F_2 = \begin{pmatrix} 1 & 0 & 0 & \frac{\sin(w)}{w} & \frac{\cos(w)-1}{w} & 0 \\ 0 & 1 & 0 & \frac{1-\cos(w)}{w} & \frac{\sin(w)}{w} & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & \cos(w) & -\sin(w) & 0 \\ 0 & 0 & 0 & \sin(w) & \cos(w) & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

其中， $w = \frac{4.8\pi}{180}$ ， $F_3 = F_2$ ，在 F_3 中， $w = \frac{-6\pi}{180}$ 。3 个模型之间的马尔科夫转移概

率矩阵的初始值为 $P_{ij} = [0.9 \ 0.05 \ 0.05; 0.1 \ 0.8 \ 0.1; 0.1 \ 0.1 \ 0.8]$ 仿真结果如下所示：




图 2.12 目标的实际位置、滤波位置




图 2.13 X 方向的滤波效果




图 2.14 Y 方向的滤波效果




图 2.15 Z 方向的目标轨迹估计




图 2.16 目标位置 RMS 误差统计




图 2.17 模型 1、2、3 的概率变化图

由图 2.13-2.15 分别给出了 X、Y、Z 三个方向上, 目标的实际轨迹与估计轨迹。由仿真结果可知, IMMPPDA 算法可以对目标进行良好的跟踪。图 2.17 表示的是目标的位置 RMS 误差, 由图可明显看出, 目标在转弯处的误差都会有所增大, 说明目标的转弯机动对跟踪性能有一定的影响, 但通过模型的切换降低跟踪误差。将

图 2.17 中各个阶段三个模型的概率变化用表 2.1 表示, 表 2.2 和 2.3 分别表示各个模型对应的运动以及各个阶段目标的运动状态。

表 2.1 各个运动模型对应的运动

模型 1	模型 2	模型 3
匀速直线运动	逆时针匀速转弯	顺时针匀速转弯

表 2.2 目标在各个时期的运动情况

时间	1~30 s	31~50 s	51~70 s	71~95 s	96~100 s
运动情况	匀速直线运动	顺时针匀速转弯	匀速直线运动	逆时针匀速转弯	匀速直线运动

表 2.3 各运动阶段 3 个模型的概率变化

时间	模型 1	模型 2	模型 3
1~30 s	大	小	小
31~50 s	小	小	大
51~70 s	大	小	小
71~95 s	较大	大	小
96~100 s	大	小	小

由图 2.17 以及表 2.1-2.3 可知, 在目标发生机动时, 算法能有效的进行模型间的转化, 从而实现对目标的运动模型匹配。需要注意的是, 由图 2.16 可以看出, 目标在 31 s~50s 这段时间的误差较大, 这主要是由于 Kalman 滤波是一种线性最优滤波器, 非线性时, Kalman 滤波器的滤波效果降低。由以上分析可知, IMMPDA 算法对强机动目标具有良好的跟踪性能。

2.5.4 联合概率数据互联算法

假设两个匀速目标作交叉运动, 初始航迹状态为:

$x_1(0) = [1 \text{ km} \ 0.35 \text{ km/s} \ 8 \text{ km} \ -0.1 \text{ km/s}]$, $x_2(0) = [1 \text{ km} \ 0.35 \text{ km/s} \ -0.8 \text{ km} \ 0.15 \text{ km/s}]$ 。过

程噪声分量 $Q_{ii} = 4 \times 10^{-4} \text{ km}^2$, 量测噪声为零均值的高斯白噪声, 其标准差

$\sqrt{R_{ii}} = 0.15 \text{ km}$, 雷达检测概率 $P_d = 0.99$, 门概率为 $P_G = 0.99$, 采用椭圆跟踪门规

则, 阈值 $\gamma = 9.21$, 采样间隔为 $T = 1 \text{ s}$, 仿真步数为 50 步, Monte Carlo 仿真次数为 100, 杂波的数目服从参数为 λ 的泊松分布, 在以目标预测值为中心的椭圆区域内服从均匀分布, 取 $\lambda = 0.5 \text{ 个/km}^2$, 仿真结果如下:

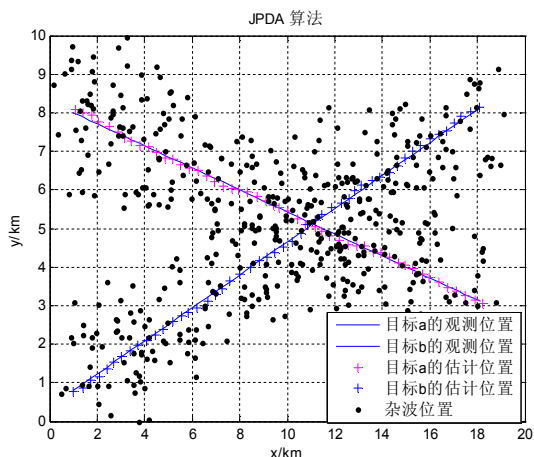


图 2.18 目标观测、滤波位置与杂波分布




图 2.19 目标的位置 RMS 误差统计

在图 2.18 中, 目标的滤波结果与真实轨迹的大致趋势是一致的, 图 2.19 中, 两个目标的位置 RMS 误差在 0.14 km 左右, 说明跟踪效果良好。在密集杂波环境下, JPDA 算法可以很好的对多目标进行跟踪。

2.6 本章小结

本章系统阐述了多目标跟踪的基本理论, 包括目标运动模型、跟踪航迹起始与终结、跟踪门的设计、滤波与预测, 主要研究了数据关联算法。数据关联一直是多目标跟踪研究的重点, 本章对经典的数据关联算法进行了研究并进行了仿真分析。

研究了适用于单目标跟踪的最近邻域法与概率数据互联算法, 并进行了仿真比较。由仿真结果可知, 密集杂波环境下, 对于非机动或弱机动的单目标和稀疏的多目标跟踪, PDA 算法性能良好, 远优于最近邻域算法, 而且概率数据互联滤波器的计算量与卡尔曼滤波器的计算量相当, 容易实现, 因此在工程中应用广泛。对于强机动目标, IMM 算法是一种性能良好的滤波算法。该算法通过对模型的切换, 能够很好的模拟目标的机动。将交互式多模型算法与概率数据互联算法结合形成的 IMM-PDA 算法, 对杂波环境下的强机动目标具有良好的跟踪性能。

联合概率数据关联算法是当前理论上最完善的一种跟踪算法, 但是随着目标和有效回波数目的增加, 其联合关联假设事件的数目呈指数增长, 导致计算量急剧增长。另一方面, 在密集杂波环境下, 当存在两个目标平行运动或以小角度交叉运动时, 可能导致轨迹的合并或交叉。因此, 如何减小计算量、抑制航迹的交叉与合并是目前 JPDA 算法研究的主流方向之一。在下一章, 将针对这两方面的问题, 对 JPDA 算法进行改进。

第三章 联合概率数据关联算法的改进

在复杂的多目标跟踪环境下, JPDAF 有着良好的跟踪性能。但当目标和有效回波数目增大时, 联合关联假设事件的数目呈指数增长, 导致 JPDA 算法的计算量出现组合爆炸现象。因此, 不少学者对 JPDA 算法提出了改进。其中 Robert Fitzgerald^[38]避开关联事件的产生, 提出一种实用的经验 JPDA 算法。该算法计算量小, 易于工程实现, 可以成功跟踪 2~3 个交叉目标, 跟踪 4 个以上目标时却存在计算量的问题。Zhou^[39]提出一种深度优化搜索方法来产生关联事件, 程洪玮^[40]推广了 Zhou 的方法, 提出分层构造互联假设事件的方法, 但是该方法的计算量仍然太大, 很难满足工程应用中实时性的要求。文献[41]提出了一种次优的 JPDA 算法, 具有良好的实时性和跟踪效果。

概率数据关联算法是一种实时性较好的关联算法, 对于稀疏的多目标跟踪有良好的跟踪性能。当目标密集时, PDA 算法未能准确考虑跟踪门相交区域中的公共回波对航迹更新的影响, 因此在目标密集时跟踪性能不理想, 特别是当目标小角度交叉或者近距离平行运动时, 容易造成目标航迹的合并或交叉。联合概率数据关联算法则被公认是解决密集回波环境下多目标数据关联的最有效算法之一。JPDA 算法的实质是计算当前所有的量测值与各航迹的互联概率, 然后用这些概率作为加权系数构造平均滤波值。PDA 算法、JPDA 算法以及各种改进 JPDA 算法之间唯一区别在于计算互联概率 $\beta_j(k)$ 的方法。PDA 算法中, 用贝叶斯法则独立计算每条航迹关联区域内出现的各个回波概率, 不考虑航迹关联区域内来自其他目标的回波。相反, JPDA 算法中, 互联概率的计算综合考虑了来自其他目标的回波。不足的是, 当这种方法推广到多目标情况时, $\beta_j(k)$ 的计算十分复杂, 常常难以解决时间与跟踪批次之间的矛盾。当接收到一个新的量测时, 必须考虑新的量测与现存航迹关联的各种可能假设, 并计算所有假设的概率。因此, 研究 $\beta_j(k)$ 的快速算法有很大的实用价值。

针对 PDA 和 JPDA 算法存在的问题, 本章提出一种适合工程应用的修正的联合概率数据关联算法 (Modified Joint Probabilistic Data Association Algorithm, MJPDA)。该算法综合研究了跟踪门相交区域中的公共回波以及跟踪门中其余候选回波对航迹状态更新的影响, 以与 PDA 相当的计算量达到接近 JPDA 算法的跟踪性能。本章的第二部分, 在传统跟踪波门的基础上, 引入方向跟踪波门, 将距离跟踪门与方向跟踪门相结合, 减少联合事件的个数, 从而达到减少计算量的目的。在引入新算法之前, 先介绍 CheapJPDA 算法。

3.1 经验联合概率数据关联算法

为了增强 JPADF 的实时性, Fitzgerald 对 JPDAF 的关联概率计算进行了改进, 提出了 CheapJPDA。在该算法中, 目标 t 与回波 j 的关联概率 β_j^t 的计算公式如下

$$\beta_j^t = \frac{G_{jt}}{S_t + S_j - G_{jt} + B} \quad (3-1)$$

式中

$$\begin{aligned} G_{jt} &= N[v_j^t(k)] \\ N[v_j^t(k)] &= \frac{1}{\sqrt{|2\pi S(k)|}} \exp\left\{-\frac{1}{2} v_j^t(k) S_t^{-1}(k) v_j^t(k)\right\} \\ S_t &= \sum_{j=1}^{m_k} G_{jt} \\ S_j &= \sum_{t=1}^T G_{jt} \end{aligned} \quad (3-2)$$

B 是一个与杂波密度有关的常数, 通常情况下, B 取 0。 G_{jt} 为量测 j 与目标 t 互联的有效似然函数, S_t 为某个目标 t 所有 G_{jt} 之和, S_j 为某个量测所有的 G_{jt} 之和, $v_j^t(k)$ 为回波 j 与目标 t 之间的新息, $S(k)$ 为新息协方差。

这种经验概率具有 JPDA 算法的特征, 对只出现在一个跟踪门内的量测做重加权, 对在几个跟踪门重叠和矛盾的量测做轻加权。但该算法对杂波影响的处理过于简单, 且每个目标的关联概率和并不等于 1, 这对多目标跟踪会带来负面影响

$$\sum_{j=1}^{m_k} \beta_j^t \neq 1 \quad (3-3)$$

3.2 修正的联合概率数据关联算法

PDA 算法是一种实时性较好的关联算法, 考虑了所有有效回波对目标航迹更新的影响, 在目标稀疏时跟踪效果理想。但是, 目标密集时, 比如多个目标做近距离的平行飞行或者以小角度交叉运动时, 会有较多的回波落入跟踪门的公共部分, PDA 算法未能正确考虑公共回波对目标航迹的影响。在这种情况下, PDA 算法的跟踪性能要远远低于 JPDA 算法, 往往会造成航迹的合并或交叉。下面举一个例子来说明 PDA 算法在多目标跟踪中存在的问题。

如图 3.1 所示, 有 3 个有效回波 1, 2, 3, 其中回波 1 是目标 1 和目标 2 的公

共回波，且回波 1 离目标 1 和目标 2 的跟踪波门中心都是最近的，在 PDA 算法中， β_1^1 和 β_1^2 都会是较大的权值，对目标 1 和目标 2 进行航迹更新时，回波 1 对两个目标都进行了重加权。实际上回波 1 只能来自于一个目标，如果对目标 2 的航迹更新进行重加权，就只能对目标 1 进行轻加权。所以，需要对存在公共回波的目标所有回波的权值进行修正。




图 3.1 跟踪门与回波实例

JPDA 算法对公共回波进行了充分的考虑与处理，因此其跟踪效果良好。但是其计算量随着跟踪目标的批数和有效回波个数的增加呈指数增加，因此也很难用于实际工程中。CheapJPDA 继承了 JPDA 的基本思想，对公共回波进行弱加权，并且绕开了联合事件的产生，所以计算量很小。但是该算法对杂波影响的处理过于简单，每个目标的关联概率和不等 1，所以会对目标的跟踪性能造成影响。本节将针对 JPDA 和 CheapJPDA 算法存在的问题，提出一种跟踪性能良好、实时性好的修正联合概率数据关联算法。

3.2.1 算法实现

假设在 k 时刻，在雷达扫描区域需要跟踪 n 个目标，目标的候选回波集合为 $Z(k) = \{z_i(k)\}_{i=1}^{m_k}$ ， $Z^k = \{Z(j)\}_{j=1}^k$ 表示到 k 时刻所有接收的有效回波， m_k 表示 k 时刻有效回波的个数。

步骤 1: 设置跟踪波门，构造大小为 $m_k \times n$ 的确认矩阵 $\Omega = [w_{jt}]$ 。与 JPDA 算法相同的是， $w_{jt} = 1$ 表示回波 j 落在目标 t 的跟踪波门中， $w_{jt} = 0$ 表示回波 j 不在目标 t 的跟踪波门中；不同的是，该矩阵的第一列不是回波与虚警的关系。

$$\Omega = \left[\begin{array}{ccc|c} \overbrace{w_{11} \cdots w_{1n}}^{t=1,2,3,\dots,n} & 1 \\ \vdots & \vdots \\ w_{m_k 1} \cdots w_{m_k n} & m_k \end{array} \right]_j \quad (3-4)$$

计算回波 j 来自于目标 t 的概率 P_j^t 以及该时刻没有量测来源于目标的概率 P_0^t

$$P_j^t = P\{\theta_j^t(k) | Z^k\} = \frac{e_j^t}{b^t + \sum_{i=1}^{m_k} e_i^t} \quad j=1, \dots, m_k \quad (3-5)$$

$$P_0^t = P\{\theta_0^t(k) | Z^k\} = \frac{b^t}{b^t + \sum_{j=1}^{m_k} e_j^t} \quad (3-6)$$

式中,

$$b^t = \lambda \left| 2\pi S^t(k) \right|^{\frac{1}{2}} \frac{1 - P_D P_G}{P_D} \quad (3-7)$$

$$e_j^t = \exp \left[-v_j^t(k)^T (k) S^t(k)^{-1} v_j^t(k) / 2 \right] \quad (3-8)$$

P_D 表示检测到真实目标的概率, P_G 表示目标真实观测落入 m 维椭球有效区域的概率, λ 为杂波密度, $v_j^t(k)$ 为量测 j 与目标 t 之间的新息。

步骤 2: 通过确认矩阵 Ω 确定该时刻的公共回波集合 Pub

$$Pub = \left\{ Pub \cup j, \text{if } \sum_{t=1}^n w_{jt} > 1, j=1, 2, 3, \dots, m_k \right\} \quad (3-9)$$

然后确定公共回波 $Pub(j)$ 可能来自目标的集合 T_j ,

$$T_j = \{T_j \cup t, \text{if } w_{jt} = 1, t=1, 2, 3, \dots, n\} \quad (3-10)$$

注意, 在每次确认 Pub 和 T_j 之前, 将 Pub 和 T_j 清零。

步骤 3: 对 Pub 中的公共回波 j 的概率值 P_j^t 进行衰减,

$$P_j^{t'} = P_j^t \frac{P_j^t}{\sum_{t_j=1}^n P_j^{t_j}}, \quad j \in Pub \quad (3-11)$$

对于非公共回波, $P_j^{t'} = P_j^t$ 。

对于 T_j 中的一个目标 t , 公共回波 j 对目标航迹状态更新的影响还应该取决于该目标跟踪波门中回波的个数, 如果回波个数越多, 公共回波 j 对航迹的影响越小; 如果回波个数越少, 公共回波 j 对航迹的影响越大。因此, 对公共回波的权值进行修正

$$\tilde{P}_j^t = P_j^{t'} \frac{P_j^{t'}}{\sum_{j=1}^{m_k} P_j^{t'}}, \quad j \in Pub \quad (3-12)$$

对于非公共回波, $\tilde{P}_j^t = P_j^{t'}$ 。

步骤 4: 对修正后的概率进行归一化,

$$\beta_j^t = \tilde{P}_j^t / \sum_{j=0}^{m_k} \tilde{P}_j^t \quad (3-13)$$

基于 β_j^t 对所有候选回波进行加权,更新所有目标的航迹状态,流程和公式同PDAF。

在该算法中,在 k 时刻,如果某条航迹不存在公共回波,则该算法退化为 PDA 算法。公共回波的权值的衰减综合考虑了公共回波与跟踪波门中心的距离以及波门中有效回波的个数。第一次衰减时,权值衰减的程度与公共回波距离波门中心的统计距离呈反比,距离波门中心近的目标衰减的程度小,距离波门中心远的回波衰减的程度大。第二次衰减时,权值衰减的程度与目标跟踪波门中的有效回波数目呈正比,跟踪波门的回波数目越多,公共回波的权值衰减程度越大。在算法的步骤 2 中,加入了目标来自于虚警的情况,充分考虑了杂波对目标航迹的影响。

3.2.2 仿真结果与分析

为了验证算法的性能,在仿真中分别考察在两个目标交叉运动、4 个目标近距离平行运动以及 4 个目标小角度交叉运动情况下,算法对目标的跟踪性能。

场景一: 两个目标交叉运动

假设两个匀速目标在二维平面上做交叉运动,目标的初始航迹状态为:

$$x_1(0) = [1 \text{ km } 0.3 \text{ km/s } 5.5 \text{ km } -0.1 \text{ km/s}] \text{ 和 } x_2(0) = [1 \text{ km } 0.3 \text{ km/s } 2.5 \text{ km } 0.1 \text{ km/s}]$$

过程噪声分量 $Q_{ii} = 4 \times 10^{-4} \text{ km}^2$, 传感器量测噪声为零均值的高斯白噪声,其标准差 $\sqrt{R_{ii}} = 0.15 \text{ km}$, $P_D = 0.9999$, 门概率 $P_G = 0.99$, 采用椭圆跟踪门规则, 阈值 $\gamma = 9.21$, 采样间隔为 $T = 1 \text{ s}$, 仿真步数为 40 步, Monte Carlo 仿真次数为 100, 杂波的数目服从参数为 λ 的泊松分布, 在以目标预测值为中心的椭圆区域内服从均匀分布。分别用 JPDA 算法、修正的联合概率数据关联算法 (MJPDA) 和 CheapJPDA 算法进行仿真, 固定各个参数, 改变杂波密度考察各算法的性能。图 3.2 与图 3.3 分别给出了杂波密度 $\lambda = 0.5 \text{ 个/km}^2$ 与 $\lambda = 1 \text{ 个/km}^2$ 时各算法的位置 RMS 误差统计。

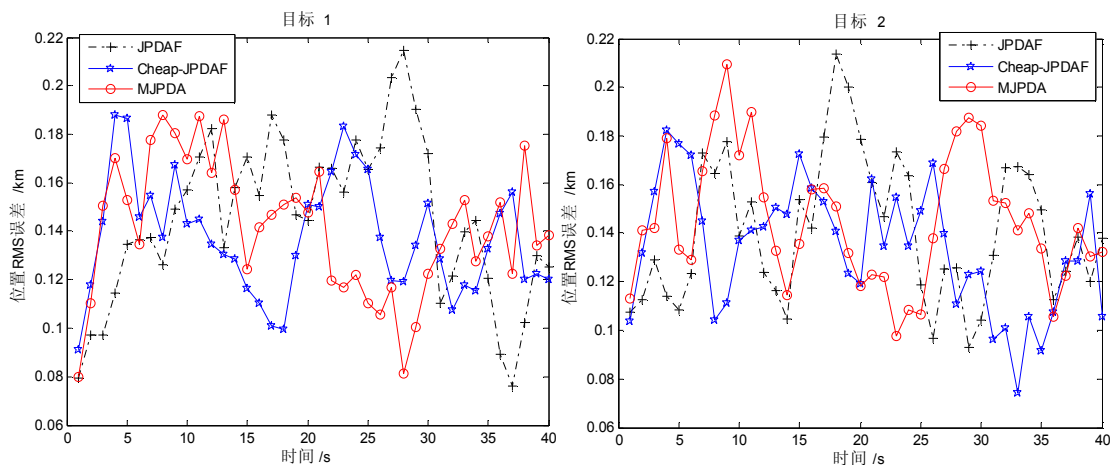



图 3.2 $\lambda = 0.5$ 时位置 RMS 误差

图 3.3 $\lambda = 1$ 时位置 RMS 误差

由仿真结果可以看出，当 $\lambda = 0.5$ 时，三种算法跟踪性能相当，都能对目标进行良好的跟踪。对于 JPDA 算法，在 $\lambda = 1$ 时，目标 1 丢失，目标 2 的跟踪性能也有所下降，这主要是由于杂波密度的增加导致可行联合矩阵的爆炸性增长，使得考虑了过多的无用杂波而导致算法性能下降。 $\lambda = 1$ 时，CheapJPDA 算法的性能也有所下降；而 MJPDA 依然能够很好的跟踪目标。

最后，表 3.1 给出了各种算法的运行时间。

表 3.1 三种跟踪算法的运行时间对比 (s)

	JPDAF	CheapJPDAF	MJPDAF
$\lambda = 0.5$	18.2156	3.9484	3.7031
$\lambda = 1$	141.0312	7.6335	8.8446

由表 3.1 可知，MJPDA 算法需要的时间与 CheapJPDA 算法的时间相当，随着有效回波数目的增加计算量线性地增长；JPDA 算法的计算量最大，有效回波数目大量增加时，联合关联假设事件的数目大量增加，造成计算量的指数增长，很难用于工程应用。

场景二：近距离平行运动

假设四个目标在二维平面上做近距离平行飞行，目标的初始航迹状态为：

$$x_1(0) = [1\text{km} \ 0.2\text{km/s} \ 1\text{km} \ 0.2\text{km/s}]、x_2(0) = [1\text{km} \ 0.2\text{km/s} \ 1.7\text{km} \ 0.2\text{km/s}]、$$

$$x_3(0) = [1\text{km} \ 0.2\text{km/s} \ 2.4\text{km} \ 0.2\text{km/s}]、x_4(0) = [1\text{km} \ 0.2\text{km/s} \ 3.1\text{km} \ 0.2\text{km/s}]，$$

进行 100 次 Monte Carlo 仿真，仿真步数为 40 步，取杂波密度 $\lambda = 0.3$ 个/ km^2 。采用 MJPDA 算法和 PDA 算法进行仿真，仿真结果如下：




图 3.4 目标的真实轨迹与杂波的分布图




图 3.5 MJPDA 算法效果图




图 3.6 PDA 算法效果图




图 3.7 MJPDA 算法位置 RMS 误差统计




图 3.8 PDA 算法位置 RMS 误差统计

由以上仿真结果可知，在密集杂波环境下，对于近距离平行运动的目标，MJPDA 算法在跟踪性能上比 PDA 算法有明显的优势。在图 3.5 中，MJPDA 算法能够对所有目标进行良好的跟踪，图 3.6 中，所有目标都偏离了自己的轨道。这主要是由于目标近距离平行运动时，相邻目标的跟踪门几乎在每个时刻都存在公共

回波。PDA 算法缺少对公共回波的正确处理，导致目标向公共回波的方向偏移，最后导致目标的交叉与合并。MJPDA 算法能够很好的解决这个问题，原因在于该算法对公共回波的权值进行了适当的衰减，抑制目标向公共回波方向偏移。例如在某一时刻，4 个目标衰减前后的的概率矩阵组成为

表 3.2 初始概率矩阵

	目标 1	目标 2	目标 3	目标 4
回波 1	0	0.2005	0.2075	0
回波 2	0.1315	0.0485	0	0
回波 3	0	0	0	0.2347
回波 4	0	0	0.1646	0
回波 5	0	0	0.0534	0
回波 6	0.8674	0.0304	0	0
回波 7	0	0.7195	0.0134	0
回波 8	0	0	0.5601	0
回波 9	0	0	0	0.7639
虚警	0.0011	0.0011	9.239e^{-4}	0.0014

表 3.3 衰减后的概率矩阵

	目标 1	目标 2	目标 3	目标 4
回波 1	0	0.0652	0.0632	0
回波 2	0.0903	0.0023	0	0
回波 3	0	0	0	0.2347
回波 4	0	0	0.1980	0
回波 5	0	0	0.0642	0
回波 6	0.9085	1.9e^{-6}	0	0
回波 7	0	0.9311	9.49e^{-8}	0
回波 8	0	0	0.6735	0
回波 9	0	0	0	0.7639
虚警	0.0012	0.0014	0.0011	0.0014

回波 6~9 分别是目标 1~4 的真实观测，其余的回波是环境中的噪声，通过对有效回波的权值进行衰减，噪声的权值基本上被缩小，真实观测的权值被放大。在计算量方面，完成 100 次 Monte Carlo 仿真，PDA 算法需要 16.7618 s，MJPDA 算法需要的时间为 10.6320 s。

场景三：小角度交叉运动

假设四个目标在二维平面上做交叉运动，目标的初始状态为：

$$x_1(0) = [2.9\text{km} \ 0.72\text{km/s} \ 3.5\text{km} \ 0.42\text{km/s}]、x_2(0) = [3\text{km} \ 0.72\text{km/s} \ 6\text{km} \ 0.25\text{km/s}]、$$

$$x_3(0) = [7.8\text{km} \ 0.45\text{km/s} \ 2.5\text{km} \ 0.6\text{km/s}]、x_4(0) = [4.5\text{km} \ 0.65\text{km/s} \ 9\text{km} \ 0.25\text{km/s}]$$

进行 100 次 Monte Carlo 仿真，仿真步数为 50 步，杂波密度 $\lambda = 0.3$ 个/ km^2 。分别采用 MJPDA 算法和 PDA 算法进行仿真，仿真结果如下：




图 3.9 MJPDA 算法的跟踪效果




图 3.10 PDA 算法的跟踪效果




图 3.11 MJPDA 算法位置 RMS 误差统计




图 3.12 PDA 算法位置 RMS 误差统计

由以上仿真结果可知，在密集杂波环境下，对于小角度交叉运动的目标，MJPDA 算法在跟踪性能上比 PDA 算法有明显的优势。MJPDA 算法能够良好地跟踪所有目标，图 3.10 中，所有目标都逐渐偏离了自己的轨道。主要原因是当目标以小角度逐渐靠近时，开始出现公共回波，PDA 算法对公共回波的权值没有进行有效的处理，导致目标向公共回波方向偏移；MJPDA 算法能够对公共回波的权值进行衰减，抑制目标向公共回波方向偏移。完成 100 次 Monte Carlo 仿真，PDA 算法需要 11.9363s，MJPDA 算法需要的时间为 11.9788 s。




图 3.13 目标的真实位置和杂波分布图

由以上三组仿真结果可知,在密集杂波环境下,MJPDA 算法对多目标能进行有效的跟踪。计算量方面,MJPDA 算法与 PDA 算法相当,随着目标数目与公共回波的数目的增长呈线性增长,易于工程实现;跟踪性能方面,MJPDA 算法与 JPDA 算法相当。综上所述,MJPDA 算法具有良好的工程应用前景。

3.3 基于联合概率数据关联算法的多重门限研究

在标准 JPDA 算法、CheapJPDA 算法和各种改进的次优 JPDA 算法中,第一步是建立跟踪门选取有效回波,最常用的跟踪波门有椭圆跟踪门、扇形波门等。密集杂波环境下,很多根本不可能的回波也落入了跟踪波门中,增加了计算量,并且对目标航迹的性能也会造成影响。因此,如何进一步限制落入波门的回波数目且不丢失真实目标,对于减小 JPDA 算法的计算量,有着实际的意义,文献[42]和[43]对数据关联算法中的多重门限问题进行了深入的研究。

本节在原有椭圆跟踪波门的基础上,引入方向跟踪门,在不丢失真实目标的前提下,减少跟踪门中的有效回波数目,以减少联合关联假设事件,从而减小 JPDA 算法计算量。在本节中,使用双跟踪门对回波进行筛选,其中,椭圆跟踪门的构造方法与以前相同,下面重点介绍方向跟踪门的构造方法。

3.3.1 方向跟踪门的构造方法

假设 $\hat{X}^t(k-1/k-1) = (\hat{x}^t(k-1), \hat{y}^t(k-1), \hat{v}_x^t(k-1), \hat{v}_y^t(k-1))$ 是 $k-1$ 时刻目标 t 的滤波值,目标 t 的预测运动方向为 θ ,

$$\theta = \arctan \left(\frac{\hat{v}_y^t(k-1)}{\hat{v}_x^t(k-1)} \right) \quad (3-14)$$

以目标 t 的预测值 $X^t(k/k-1) = (x^t(k/k-1), y^t(k/k-1), v_x^t(k/k-1), v_y^t(k/k-1))$ 为中心建立椭圆跟踪波门， $Z_g(k) = (x_g(k), y_g(k))$ 为落入椭圆跟踪门的一个有效回波。

将回波 $Z_g(k)$ 与目标的 t 的滤波值 $\hat{X}^t(k-1/k-1)$ 连接起来，定义该连线与目标预测方向的夹角为回波 $Z_g(k)$ 的拟方向，如图 3.14 所示。




图 3.14 回波 $Z_g(k)$ 的拟方向

由图可知，回波 $Z_g(k)$ 对应的拟方向为

$$\varepsilon = \theta - \arctan \left(\frac{y_g(k) - \hat{y}^t(k-1)}{x_g(k) - \hat{x}^t(k-1)} \right) \quad (3-15)$$

方向跟踪门可表示为

$$|\varepsilon| \leq K_g \sigma_\theta \quad (3-16)$$

其中，系数 K_g 由门概率 P_g 确定， σ_θ 是预测方向的标准方差，下面讨论如何确定 σ_θ 。

对式 (3-14) 中的 θ 线性化，并忽略高阶无穷小量，可得

$$\Delta\theta = \frac{\partial\theta}{\partial v_x} \Delta v_x + \frac{\partial\theta}{\partial v_y} \Delta v_y \quad (3-17)$$

式中， $\frac{\partial\theta}{\partial v_x} = -\frac{v_y}{v_x^2 + v_y^2}$ ， $\frac{\partial\theta}{\partial v_y} = -\frac{v_x}{v_x^2 + v_y^2}$ 。

所以误差的均值和方差为

$$E[\Delta\theta] = -\frac{1}{v_x^2 + v_y^2} (v_y E[\Delta v_x] + v_x E[\Delta v_y]) \quad (3-18)$$

$$E[(\Delta\theta)^2] = \frac{1}{(v_x^2 + v_y^2)^2} \left(v_y^2 E[(\Delta v_x)^2] + v_x^2 E[(\Delta v_y)^2] + 2v_x v_y E[\Delta v_x] E[\Delta v_y] \right) \quad (3-19)$$

在 k 时刻, 经过椭圆跟踪门和方向跟踪门筛选后的回波个数要比只经过椭圆跟踪门筛选得到的回波个数要少, 减少了联合关联假设事件的个数, 从而达到减少计算量的目的, 下面将验证这种方法的可行性。

3.3.2 仿真结果与分析

假设两个匀速目标在二维平面上做交叉运动, 目标的初始航迹状态为:

$$x_1(0) = [1\text{km} \ 0.35\text{km/s} \ 8\text{km} \ -0.1\text{km/s}] \text{ 和 } x_2(0) = [1\text{km} \ 0.35\text{km/s} \ 0.8\text{km} \ 0.15\text{km/s}]$$

过程噪声分量 $Q_{ii} = 4 \times 10^{-4} \text{ km}^2$, 传感器量测噪声为零均值的高斯白噪声, 其标准差 $\sqrt{R_{ii}} = 0.15 \text{ km}$, 探测概率 $P_D = 0.99$, 门概率 $P_G = 0.99$, 采样间隔 $T = 1 \text{ s}$, 仿真步数为 50 步, Monte Carlo 仿真次数为 100, 杂波的数目服从 $\lambda = 0.5 \text{ 个/km}^2$ 的泊松分布, 在以目标预测值为中心的椭圆区域内服从均匀分布。先使用单一椭圆跟踪门的 JPDA 算法进行仿真, 门限值 $\gamma = 9.21$, 在相同的仿真条件下, 使用双跟踪门进行仿真, 仿真结果如下:

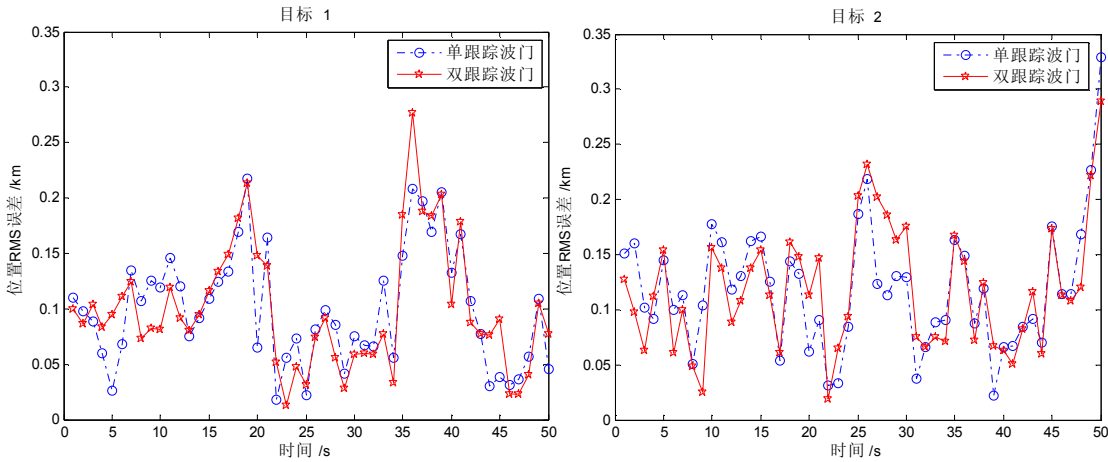


图 3.15 单跟踪波门与双跟踪波门的位置 RMS 误差对比

由图 3.15 可知, 两种方法的跟踪性能基本相当, 下面考察两种方法的计算量。两个目标在 30 s 时靠的最近, 此时的关联过程比较复杂, 因此我们选择 26~34 s 这段时间的确认矩阵对进行分析。

$T = 26 \sim 34 \text{ s}$ 期间, 单跟踪门的确认矩阵

$$\Omega_{26} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 1 & 0 & 0 & 1 \end{bmatrix}^T, \quad \Omega_{27} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \end{bmatrix}^T, \quad \Omega_{28} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 1 & 1 \end{bmatrix}^T,$$

$$\begin{aligned}
\Omega_{29} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 0 & 1 & 1 \end{bmatrix}^T, \quad \Omega_{30} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}^T, \quad \Omega_{31} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{bmatrix}^T, \quad \Omega_{32} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{bmatrix}^T, \\
\Omega_{33} &= \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & 1 \end{bmatrix}^T, \quad \Omega_{34} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 & 1 & 1 & 0 \end{bmatrix}^T, \quad \text{与此对应的双跟踪} \\
\text{波门的确认矩阵为 } \Omega'_{26} &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}^T, \quad \Omega'_{27} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{bmatrix}^T, \quad \Omega'_{28} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 0 & 1 & 1 \end{bmatrix}^T, \\
\Omega'_{29} &= \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix}^T, \quad \Omega'_{30} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 1 \end{bmatrix}^T, \quad \Omega'_{31} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix}^T, \quad \Omega'_{32} = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix}^T, \\
\Omega'_{33} &= \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix}^T, \quad \Omega'_{34} = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}^T
\end{aligned}$$

然后根据确认矩阵拆分原则，对确认矩阵 $\Omega_{26} \sim \Omega_{34}$ 和 $\Omega'_{26} \sim \Omega'_{34}$ 进行拆分，得到的联合关联假设事件数目为

表 3.4 联合关联假设事件数目

	N_{26}	N_{27}	N_{28}	N_{29}	N_{30}	N_{31}	N_{32}	N_{33}	N_{34}
单一门限	21	11	22	10	13	21	21	31	21
双重门限	6	7	10	7	5	7	8	12	7

由以上拆分结果可知，与单一椭圆跟踪波门的联合关联假设事件的数目相比，经过椭圆和方向跟踪波门限制后的联合关联假设事件数目明显减少，从而减少了联合关联假设事件概率的计算。特别是当目标个数较多、运动情况复杂时，两种算法的联合关联假设事件个数相差会更明显。因此，基于双跟踪波门的 JPDA 算法能够大大减少基于单一跟踪波门的 JPDA 算法的计算量。

这种方法存在的问题在于式 (3-14)、(3-15) 中反正弦的计算会占用较多的时间，从而影响算法的实时性。在工程应用中，可将正弦值与对应的角度值存入计算机内存中。筛选有效回波时，实时求得回波拟方向的正弦值，查表得到对应的拟方向以减少运算量。

3.4 本章小节

本章主要是针对 JPDA 算法计算量存在的问题,提出了修正的联合概率数据关联算法。该算法继承了标准 JPDA 算法和 CheapJPDA 算法对公共回波弱加权、只属于一个目标的回波进行重加权的思想,引入了杂波影响的考虑,对有效回波的权值进行了相应的处理,克服了 CheapJPDA 算法的弱点。仿真结果表明,该算法能够达到与 JPDA 算法相当的跟踪性能,计算量与 PDA 算法相当,计算量随着目标数目与公共回波的数目的增长呈线性增长,满足工程应用的要求。

在本节的第二部分,引进了方向跟踪波门,将方向跟踪门与椭圆跟踪门相结合,对回波进行筛选。仿真结果表明,与单一的椭圆跟踪门相比,双跟踪波门能够有效减少有效回波的数目,以减少联合关联假设事件的数目,从而达到减小计算量的目的。

第四章 基于模糊聚类的多目标数据关联算法

Bar-Shalom 等人提出的 JPDA 算法在复杂回波环境下对多目标有着良好的跟踪性能,但是联合概率的计算过于复杂,计算量随着目标和回波数目的增长呈指数增长。多假设跟踪算法尝试保持所有可能关联假设的航迹,但这是一个 NP-hard 问题,关联假设数目随着时间呈指数递增。事实上,数据关联可以看做是一个量测集与目标的分类问题。由于数据关联问题本身的不确定性,一些学者将模糊数学理论用于解决多目标跟踪中的数据关联问题,提出了一些基于模糊聚类的数据关联算法。1974 年, Dunn 和 Bezdek 提出了模糊 C-均值 (fuzzy C-means, FCM) 算法。文献[31]成功地将 FCM 算法用于解决多目标跟踪中的数据关联,降低了计算的复杂度,减少了计算时间。Mourad Oussalah 和 Schutter^[26]基于模糊 C 均值聚类,提出了适用于单目标跟踪的混合模糊概率数据关联算法和适用于多目标跟踪的混合模糊联合概率数据关联算法。文献[44]在模糊聚类中引入信息熵,得到最大熵意义下的模糊聚类算法, Liu^[46]和 Li^[45]都将最大熵模糊聚类算法用于对目标进行实时跟踪。

模糊聚类关联算法是以模糊均值聚类算法为基础,通过使目标函数最小化把量测数据分别划分到以目标预测位置为中心的类中,从而实现数据关联。本章研究了 C-均值聚类算法和最大熵模糊聚类算法。本章采用最大熵模糊聚类算法实现数据关联,并对权值的再分配问题进行研究,解决复杂环境下的多目标数据关联问题。

4.1 C-均值聚类算法

设在 \mathfrak{R}^s 空间中,给定一个有限数据集 $X = \{x_1, x_2, \dots, x_n\}$, $U = \{u_{ij}\}_{c \times n}$ 是隶属度矩阵, $v = \{v_1, v_2, \dots, v_c\}$ 是 c 个聚类中心。C-均值聚类算法把 n 个向量 $x_i (i = 1, 2, \dots, n)$ 分为 c 个簇,并求得每个簇的聚类中心,使隶属度的二次方对误差平方的加权最小。定义目标函数为

$$J(U, V) = \sum_{k=1}^n \sum_{i=1}^c u_{ik} (d_{ik})^2 \quad (4-1)$$

其中 $\sum_{i=1}^c u_{ik} = 1 \quad \forall k$, $u_{ik} \in \{0, 1\}$, $d_{ik} = |x_k - v_i|$ 。C-均值聚类算法的基本步骤如下:

步骤 1: 给出初始聚类中心 $v^{(0)} = \{v_1^{(0)}, v_2^{(0)}, \dots, v_c^{(0)}\}$, 迭代次数 $l = 0$, 最大迭代次数为 T , 阈值为 ε 。

步骤 2:用下列公式更新 $u_{ik}^{(l+1)}$:

$$u_{ik}^{(l+1)} = \begin{cases} 1, & \text{if } i = \operatorname{argmin}\{|x_k - v_i^{(l)}|\} \\ 0, & \text{other} \end{cases} \quad (4-2)$$

步骤 3:用下列公式更新 $v_i^{(l+1)}$:

$$v_i^{(l+1)} = \frac{\sum_{k=1}^n u_{ik}^{(l+1)} x_k}{\sum_{k=1}^n u_{ik}^{(l+1)}} \quad (4-3)$$

如果 $\max_i \|v_i^{(l+1)} - v_i^{(l)}\| < \varepsilon$ 或者 $l > T$, 则停止; 否则, $l = l + 1$, 转至步骤 2。

C-均值算法思想简单, 实现容易, 收敛快, 能够有效处理大数据集, 是目前最常用的聚类算法之一。但是 C-均值算法也存在很多缺点, 如没有考虑对类中心的约束, 所有数据点的影响都是被假定是相同的, 缺少对噪声数据的考虑等。在 C-均值算法中, 隶属度是一个二进制数, 不是 1 就是 0, 这并不能反映类中心与数据点的实际关系。对于这个问题, 学者们引入模糊数学的理论, 形成模糊聚类算法。模糊聚类算法主要思想是将经典划分的定义模糊化, 现在主要有两种比较成功的思路: 一是在 C-均值算法的目标函数中引入隶属度函数的权重指数, 二是在 C-均值算法的目标函数中引入信息熵。

4.2 改进的最大熵模糊联合概率数据关联算法

4.2.1 改进的最大熵模糊聚类

模糊聚类通过最小化目标函数, 把量测数据划分到以目标预测位置为中心的类中。划分后, 每个量测通过隶属度 u_{ij} 分类到相应的目标, u_{ij} 反映了量测与目标之间的关联概率。假设 k 时刻有 N 个有效数据 $\{x_i, i=1, 2, \dots, N\}$, c 个类的中心 $\{c_j, j=1, 2, \dots, c\}$ 。因此, 聚类过程可以描述为以下的优化过程, 代价函数为

$$E = \sum_{i=1}^N \sum_{j=1}^c u_{ij} \cdot d(x_i, c_j) \quad (4-4)$$

其中 u_{ij} 是数据 x_i 与聚类中心 c_j 之间隶属度, $d(x_i, c_j)$ 表示 x_i 与聚类中心 c_j 之间的

Mahalanobis 距离 $d(x_i, c_j) = (x_i - c_j)' S_i^{-1} (x_i - c_j)$, 且服从约束: $\sum_{j=1}^c u_{ij} = 1 \quad \forall u_{ij} \in [0, 1]$ 。

根据信息论, 为了最小无偏的描述数据点与聚类中心的隶属度, 采用最大熵原理

将熵最大化, 由香农熵原理得 $H = H(u_{ij}) = -\sum_{i=1}^N \sum_{j=1}^c u_{ij} \ln u_{ij}$ 。采用 Lagrange 乘数法,

目标函数可以定义为：

$$J_m(U, C) = -\sum_{i=1}^N \sum_{j=1}^c u_{ij} \ln u_{ij} - \sum_{i=1}^N \alpha_i \sum_{j=1}^c u_{ij} \cdot d(x_i, c_j) + \sum_{i=1}^N \lambda_i (\sum_{j=1}^c u_{ij} - 1) \quad (4-5)$$

将目标函数最大化，可得数据 x_i 与聚类中心 c_j 之间的隶属度：

$$u_{ij} = \frac{e^{-\alpha_i d(x_i, c_j)}}{\sum_{k=1}^N e^{-\alpha_k d(x_k, c_j)}} \quad (4-6)$$

α_i 是最大熵过程中的 Lagrange 乘子。通过改变 α_i 可以调整数据 x_i 与最近聚类中心 c_j 及其它类中心的隶属度值。因此，通常称 α_i 为“差异因子”。

4.2.2 最佳差异因子 $\alpha_{i(opt)}$

$\alpha_{i(opt)}$ 通常可以最小化式 (4-4) 得到，研究表明，对于任意给定的聚类中心 c_j ，代价函数 E 随 α_i 的增加单调地呈指数递减。因此，当 E 趋于稳定，即 $\partial E / \partial \alpha_i \rightarrow 0$ 时， α_i 趋于最优值。在式 (4-4) 中对参数 α_i 求一阶导数可得：

$$\frac{\partial E}{\partial \alpha_i} = \sum_{i=1}^N \sum_{j=1}^c \frac{d(x_i, c_j)}{Z_i^2} \exp(-\alpha_i d(x_i, c_j)) \times \left[-d(x_i, c_j) Z_i + \sum_{j=1}^c d(x_i, c_j) \exp(-\alpha_i d(x_i, c_j)) \right] \quad (4-7)$$

式中， $Z_i = \sum_{j=1}^c \exp(-\alpha_i d(x_i, c_j))$ ，对于任一数据 x_i ，将离它最近的聚类中心记为 c_p ，即 $d(x_i, c_p) < d(x_i, c_q)$ ($q = 1, 2, \dots, c, \text{ and } q \neq p$)，定义 $d_{i(\min)}$ 为数据 x_i 与最近聚类中心 c_j 的距离， $d_{i(\min)} = d(x_i, c_p) = \min\{d(x_i, c_j) | j = 1, \dots, c\}$ 。当满足 $\exp(-\alpha_{i(opt)} d(x_i, c_p)) = \exp(-\alpha_{i(opt)} d_{i(\min)}) = \varepsilon$ 时可得到 $\alpha_{i(opt)}$ 。其中， ε 是一个很小的正数， $\exp(-\alpha_i d(x_i, c_q)) \leq \varepsilon$ ， $\forall q$ 。此时，

$$\frac{\partial E_i}{\partial \alpha_i} = \sum_{j=1}^c \frac{d(x_i, c_j)}{Z_i^2} \exp(-\alpha_i d(x_i, c_j)) \times \left[-d(x_i, c_j) Z_i + \sum_{j=1}^c d(x_i, c_j) \exp(-\alpha_i d(x_i, c_j)) \right] \rightarrow 0 \quad (4-8)$$

由于 $\frac{\partial E}{\partial \alpha_i} = \sum_{i=1}^N \frac{\partial E_i}{\partial \alpha_i}$, 所以式 (4-8) 等价于 $\frac{\partial E}{\partial \alpha_i} \rightarrow 0$, 因此

$$\alpha_{i(opt)} = -\ln(\varepsilon)/d_{i(min)} \quad (4-9)$$

α_i 值越大, 越靠近类中心的数据的隶属度越大; 对于目标数据关联, 离目标预测位置越近的观测, 关联概率应该越大; 回波的数目越多, 目标丢失的概率也就越大。因此, 杂波密度较低时, α_i 应较大; 杂波密度较高时, α_i 应较小。即 α_i 的值与杂波密度 λ 成反比, 因此 α_i 可以定义为:

$$\alpha_i = \eta/\lambda \cdot d_{i(min)} \quad (4-10)$$

式中, $\eta \in [0,1]$ 。

研究发现, α_i 选定后, 隶属度 u_{ij} 随 d 的增加呈指数递减, d 很小的增加会引起隶属度 u_{ij} 的急剧减少。 α_i 的这一特性在本算法中能够有助于计算量的减小。对于落入跟踪波门中的有效回波, 只要有效回波与目标预测位置的 d 足够大, 则认为此观测是无效观测, 予以剔除, 减少了滤波算法的计算量。下面给出剔除无效观测的具体方法^[45]。

将式 (4-10) 代入式 (4-6), 可得

$$u_{ij} = e^{-\frac{\eta}{\lambda \cdot d_{i(min)}} d(x_i, c_j)} / \sum_{k=1}^N e^{-\frac{\eta}{\lambda \cdot d_{k(min)}} d(x_k, c_j)} \quad (4-11)$$

$$\begin{aligned} u_{ij(max)} &= \frac{e^{-\frac{\eta}{\lambda \cdot d_{i(min)}} d(x_i, c_j)}}{\sum_{k=1}^N e^{-\frac{\eta}{\lambda \cdot d_{k(min)}} d(x_k, c_j)}} = \frac{e^{-\frac{\eta}{\lambda \cdot d_{i(min)}} d_{i(min)}}}{\sum_{k=1, k \neq i}^N e^{-\frac{\eta}{\lambda \cdot d_{k(min)}} d(x_k, c_j)} + e^{-\frac{\eta}{\lambda \cdot d_{i(min)}} d_{i(min)}}} \\ &= e^{-\frac{\eta}{\lambda}} / \left(\sum_{k=1, k \neq i}^{m_k} e^{-\frac{\eta}{\lambda \cdot d_{i(min)}} d(x_k, c_j)} + e^{-\frac{\eta}{\lambda}} \right) \end{aligned} \quad (4-12)$$

由 (4-12) 可知, 分子是一个常数, 而分母可以近似地认为是一个常数, 所以最大隶属度 $u_{ij(max)}$ 可以近似为一个常数。因此, 当 $u_{kj(k \neq i)} / u_{ij(max)} \leq \xi$ (ξ 为很小的正常数, 如 $\xi = 10^{-3}$ 或更小) 时, 观测 k 对于目标状态更新的影响变得很小。为了减少计算量, 可认为观测 k 无效。于是可按如下方法确定门限:

$$\begin{aligned}
u_{kj(k \neq i)} / u_{ij(\max)} &= e^{-\frac{\eta}{\lambda d_{i(\min)}} d(x_k, c_j)} / e^{-\frac{\eta}{\lambda}} \geq \xi \\
\Leftrightarrow d_{k(k \neq i)} &\leq -\frac{\lambda \ln(\xi)}{\eta} d_{i(\min)} + d_{i(\min)} = (1 - \frac{\lambda \ln(\xi)}{\eta}) d_{i(\min)} \\
\Leftrightarrow d_{k(k \neq i)} &\leq (1 - \lambda \ln(\xi) / \eta) d_{i(\min)} = D_{\max}
\end{aligned} \tag{4-13}$$

从式 (4-13) 可以看出, 观测 k 与聚类中心 c_j 的距离只有小于最大有效距离 D_{\max} 时, 观测 k 才被认为是有效。此外, 由于最小距离 $d_{i(\min)}$ 每个时刻都不同, 所以 D_{\max} 可以根据观测的分布自适应地调整。

4.2.3 算法实现

假设在 k 时刻, 在雷达扫描区域需要跟踪 n 个目标, 目标的候选回波集合为 $Z(k) = \{z_i(k)\}_{i=1}^{m_k}$, $Z^k = \{Z(j)\}_{j=1}^k$ 表示到 k 时刻所有接收的有效回波, m_k 表示 k 时刻有效回波的个数。将 $Z(k)$ 看做是数据集合, 将 N 个目标的预测位置看做是类的中心, 可以将最大熵模糊聚类算法用于多目标跟踪的数据关联, 具体的算法如下:

步骤 1: 设置跟踪波门, 构造大小为 $m_k \times n$ 的确认矩阵 $\Omega = [w_{jt}]$, $w_{jt} = 1$ 表示回波

j 落在目标 t 的跟踪波门中, $w_{jt} = 0$ 表示回波 j 不在目标 t 的跟踪波门中;

$$\Omega = \left[\begin{array}{ccc|c} \overbrace{w_{11} \cdots w_{1n}}^{t=1,2,3,\dots,n} & 1 \\ \vdots & \vdots \\ w_{m_k 1} \cdots w_{m_k n} & m_k \end{array} \right] j \tag{4-14}$$

计算回波 j 可能来自于目标 t , 其概率 P_j^t 可看做最大熵模糊聚类中量测 j 与目标 t 的预测位置之间的隶属度 u_{jt} , 由式 (4-6) 获得。同时, 考虑该时刻没有量测来源于目标 t 的概率

$$P_0^t = \lambda(1 - P_d P_g) \tag{4-15}$$

步骤 2: 通过确认矩阵 Ω 确定该时刻的公共回波集合 Pub

$$Pub = \left\{ Pub \cup j, \text{if } \sum_{t=1}^n w_{jt} > 1, j = 1, 2, 3, \dots, m_k \right\} \tag{4-16}$$

对 Pub 中的公共回波 j 的概率值 P_j^t 进行衰减,

$$P_j^t = P_j^t \frac{P_j^t}{\sum_{t_j=1}^N P_j^{t_j}}, j \in Pub \tag{4-17}$$

对于非公共回波， $P_j^{t'} = P_j^t$ 。

步骤 3: 计算互联概率 β_j^t 和 β_0^t

$$\beta_j^t = \frac{P_j^{t'}}{\sum_{i=1}^{m_k} P_i^{t'} + P_0^t} \quad t=1,2,\dots,N \quad (4-18)$$

$$\beta_0^t = \frac{P_0^t}{\sum_{i=1}^{m_k} P_i^{t'} + P_0^t} \quad (4-19)$$

步骤 4: 对公共回波的互联概率进行衰减

$$\beta_j^{t'} = \beta_j^t \frac{\beta_j^t}{\sum_{t_j=1}^N \beta_j^{t_j}}, \quad j \in Pub \quad (4-20)$$

对于非公共回波， $\beta_j^{t'} = \beta_j^t$ 。

步骤 5: 对各个目标的互联概率进行归一化

$$\beta_j^t = \frac{\beta_j^{t'}}{\sum_{i=1}^{m_k} \beta_i^{t'} + \beta_0^t} \quad t=1,2,\dots,N \quad (4-21)$$

$$\beta_0^t = \frac{\beta_0^t}{\sum_{i=1}^{m_k} \beta_i^{t'} + \beta_0^t} \quad (4-22)$$

基于 β_j^t 对所有候选回波进行加权，更新目标的航迹状态，流程和公式同 PDAF。

以上将最大熵模糊聚类算法应用于多目标跟踪的数据关联算法的流程，进行单目标跟踪时，只需计算有效回波 $j(j=1,2,\dots,m_k)$ 与目标预测值之间的隶属度 u_j ，则回波 j 与目标之间的互联概率 $\beta_j = u_j$ ，然后基于 β_j 对所有候选回波进行加权，更新目标的航迹状态，流程和公式同 PDAF。

4.3 仿真结果与分析

为了验证算法的性能，本节采用以下三个例子：两个目标交叉运动、4 个目标近距离平行运动以及 4 个目标小角度交叉运动。

4.3.1 两个目标交叉运动

假设两个匀速目标在二维平面上做交叉运动，目标的初始航迹状态为：

$$x_1(0) = [1 \text{ km } 0.3 \text{ km/s } 5.5 \text{ km } -0.1 \text{ km/s}] \text{ 和 } x_2(0) = [1 \text{ km } 0.3 \text{ km/s } 2.5 \text{ km } 0.1 \text{ km/s}],$$

过程噪声分量 $Q_{ii} = 4 \times 10^{-4} \text{ km}^2$ ，传感器量测噪声为零均值的高斯白噪声，其标准差

$$\sqrt{R_{ii}} = 0.15 \text{ km}，\text{雷达探测概率 } P_D = 0.98，\text{门概率为 } P_G = 0.99，\text{采用椭圆关联门规则，}$$

门限值 $\gamma = 9.21$ ，采样间隔为 $T = 1 \text{ s}$ ，仿真步数为 50 步，Monte Carlo 仿真次数为 100，杂波的数目服从参数为 λ 的泊松分布，在以目标预测值为中心的椭圆区域内服从均匀分布。

分别用 JPDA 算法、改进的最大熵模糊联合概率数据关联（MEF-JPDA）算法和 CheapJPDA 算法进行仿真，固定各个参数，改变杂波密度考察各算法的性能。

图 4.1 与图 4.2 分别给出了杂波密度 $\lambda = 0.5$ 与 $\lambda = 1$ 时各算法的位置 RMS 误差统计。




图 4.1 $\lambda = 0.5$ 时位置 RMS 误差

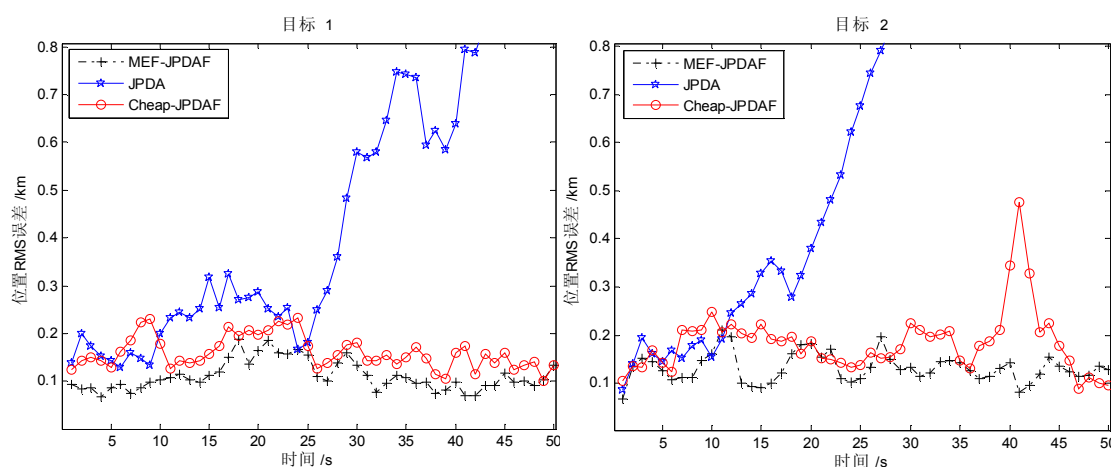


图 4.2 $\lambda = 1$ 时位置 RMS 误差

由仿真结果可以看出，当 $\lambda = 0.5$ 时，三种算法都能对目标进行良好的跟踪，

Cheap-JPDA 算法和 JPDA 算法跟踪性能相当, MEF-JPDA 算法的性能最优。对于 JPDA 算法, 在 $\lambda=1$ 时, 目标 1、2 都丢失, 这主要是由于杂波密度的增加导致可行联合矩阵的爆炸性增长, 算法考虑了过多的无用杂波而引起算法性能的下降。 $\lambda=1$ 时, CheapJPDA 算法的性能有所下降, 但依然保持对目标的跟踪。MEF-JPDA 算法依然能够很好的跟踪目标, 主要原因有 3 个: 1) 最大熵模糊聚类算法中有效回波与目标之间的隶属度能够更精确的反映候选回波与目标之间的权值关系; 2) MEF-JPDAF 能够有效剔除大于 D_{\max} 的无效回波, 在 JPDA 和 Cheap-JPDA 算法中认为这些回波是有效回波; 3) MEF-JPDAF 对公共回波的权值进行衰减, 对非公共回波的权值进行扩大, 抑制航迹向公共回波方向偏移。

最后, 表 4.1 给出了各算法的运行时间。

表 4.1 三种跟踪算法的运行时间对比 (s)

	JPDA	Cheap-JPDA	MEF-JPDA
$\lambda = 0.5$	16.807	4.826	5.117
$\lambda = 1$	132.052	10.264	7.491

由表可知, 当 $\lambda=0.5$ 时, CheapJPDA 算法的计算速度与 MEF-JPDA 算法相当, 要快于 JPDA 算法。CheapJPDA 算法的速度要略快于 MEF-JPDA 算法, 这主要是由于 MEF-JPDA 算法对权值的重建要比 CheapJPDA 算法复杂。当 $\lambda=1$ 时, MEF-JPDA 算法的速度要快于 CheapJPDA 算法, 这主要是由于 MEF-JPDA 算法剔除大于最大有效距离 D_{\max} 的候选回波, 从而减小了计算量。

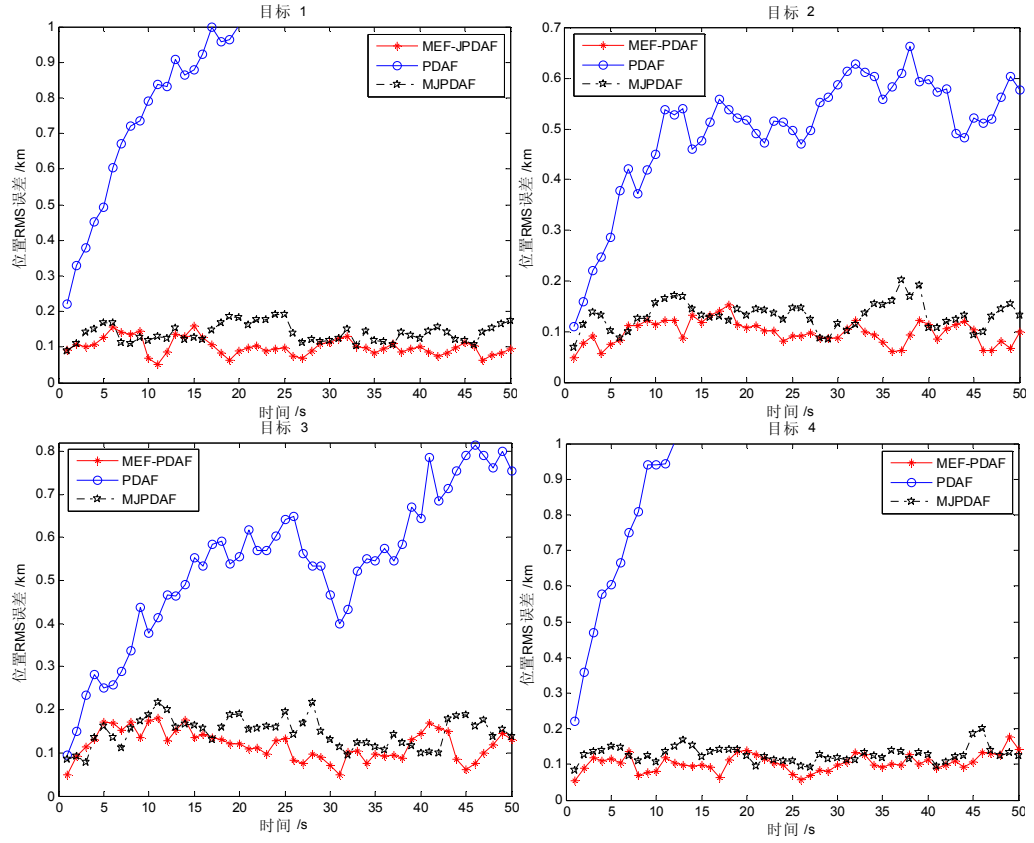
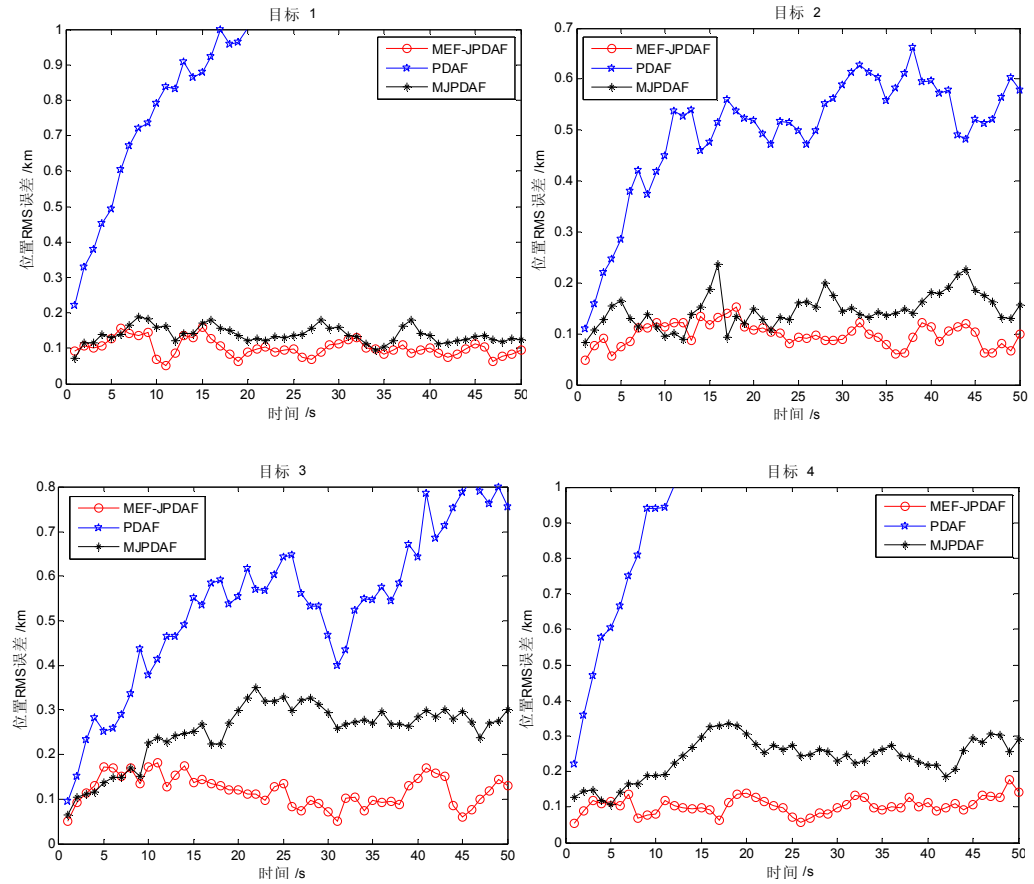
4.3.2 四个近距离平行目标

假设四个目标在二维平面上做近距离平行运动, 目标的初始状态为:

$$x_1(0) = [1\text{km} \ 0.2\text{km/s} \ 1\text{km} \ 0.2\text{km/s}], \quad x_2(0) = [1\text{km} \ 0.2\text{km/s} \ 1.7\text{km} \ 0.2\text{km/s}],$$

$$x_3(0) = [1\text{km} \ 0.2\text{km/s} \ 2.4\text{km} \ 0.2\text{km/s}], \quad x_4(0) = [1\text{km} \ 0.2\text{km/s} \ 3.1\text{km} \ 0.2\text{km/s}],$$

100 次 Monte Carlo 仿真, 仿真步数为 50 步。分别采用 MJPDAF、MEF-JPDAF 和 PDAF 进行仿真, 过程噪声 ($Q_{ii} = 4 \times 10^{-4} \text{ km}^2$) 和量测误差方差 ($\sqrt{R_{ii}} = 0.15 \text{ km}$), 考察杂波密度对算法的影响, 图 4.3-4.4 分别给出了杂波密度 $\lambda=0.25$ 和 $\lambda=0.5$ 时各算法的位置 RMS 误差统计情况。

图 4.3 $\lambda = 0.25$ 时各个目标的位置 RMS 误差图 4.4 $\lambda = 0.5$ 时各个目标的位置 RMS 误差

可以看出,对于 PDAF,在目标密集时,相邻目标存在公共回波,使目标向公共回波方向倾斜,导致目标的合并或交叉,造成所有的目标丢失;当 $\lambda = 0.25$ 时, MJPDFAF 与 MEF-JPDFAF 算法都能对所有目标进行良好的跟踪,MEF-JPDFAF 的跟踪性能要好于 MJPDFAF;随着杂波的增加,当 $\lambda = 0.5$ 时, MJPDFAF 的跟踪性能下降,最小均方误差增大,MEF-JPDFAF 依然能够很好的跟踪目标。

最后,表 4.2 给出了各算法的运行时间。由表 4.2 可以看出,当 $\lambda = 0.25$ 时, PDAF 的计算量最小, MJPDFAF 和 MEF-JPDFAF 的计算量相当;杂波密度的变大 ($\lambda = 0.5$) 时, MEF-JPDFAF 的运行时间最短。主要的原因是随着杂波密度的增加,三种算法中只有 MEF-JPDFAF 能够剔除落入跟踪门中距离大于 D_{\max} 的无效回波,减少计算量。由表 5.3 可知,随着杂波密度的增加,MEF-JPDFAF 的计算量没有急速增长,克服了 JPDFAF 计算量爆炸性增长的问题。

表 4.2 三种跟踪算法的运行时间对比 (s)

	PDAF	MJPDFAF	MEF-JPADF
$\lambda = 0.25$	11.9283	12.7760	15.1248
$\lambda = 0.5$	24.2074	21.3658	20.9884

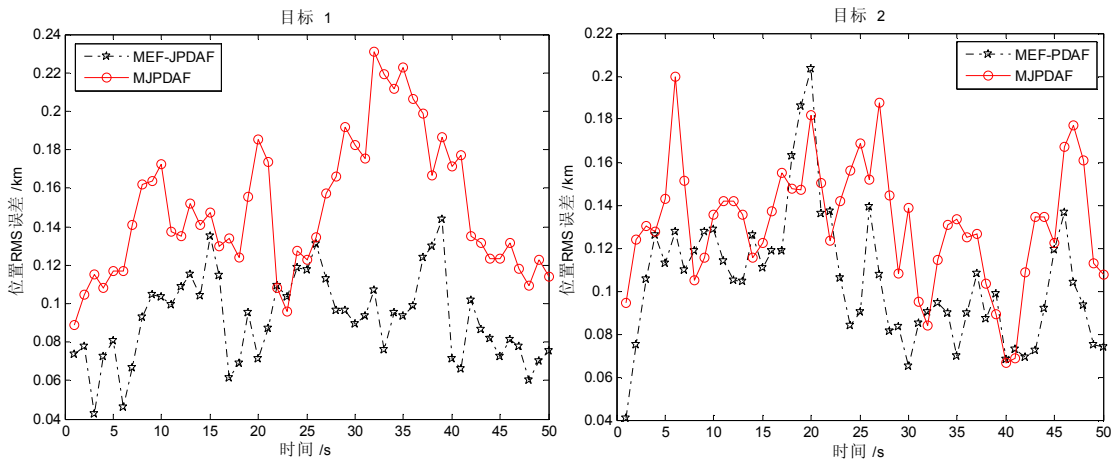
4.3.3 四个小角度交叉目标

四个目标在二维平面上做交叉运动,目标的初始航迹状态为:

$$x_1(0) = [2.9\text{km} \ 0.72\text{km/s} \ 3.5\text{km} \ 0.42\text{km/s}]、x_2(0) = [3\text{km} \ 0.72\text{km/s} \ 6\text{km} \ 0.25\text{km/s}]、$$

$$x_3(0) = [7.8\text{km} \ 0.45\text{km/s} \ 2.5\text{km} \ 0.6\text{km/s}]、x_4(0) = [4.5\text{km} \ 0.65\text{km/s} \ 9\text{km} \ 0.25\text{km/s}]$$

进行 100 次 Monte Carlo 仿真,仿真步数为 50 步。分别采用 MJPDFAF 和 MEF-JPDFAF 进行仿真,过程噪声 ($Q_{ii} = 4 \times 10^{-4} \text{ km}^2$) 和量测误差方差 ($\sqrt{R_{ii}} = 0.15 \text{ km}$),杂波密度 $\lambda = 0.5$ 个/ km^2 ,两种算法的位置 RMS 误差统计情况如图 (4.5) 所示。



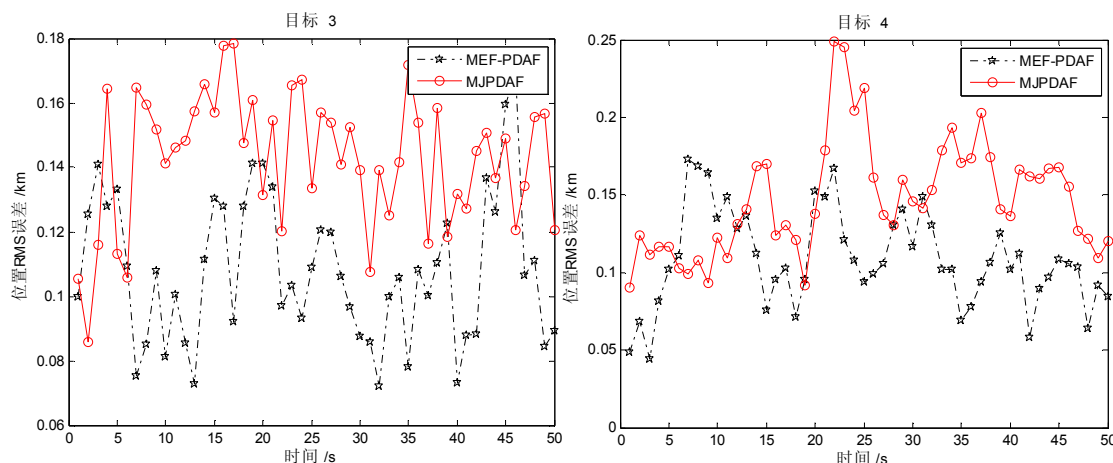


图 4.5 各个目标的位置 RMS 误差

由仿真结果, 当目标做小角度交叉运动时, MEF-JPDAF 和 MJPDAF 都能很好的跟踪目标, MEF-JPDAF 的跟踪性能要略优于 MJPDAF。完成 100 次 Monte Carlo 仿真, MEF-JPDAF 需要 18.0062 s, MJPDAF 需要 16.0151 s, 两种方法计算量相当。

由上面的三组仿真实验可知, MEF-JPDAF 在杂波环境下能够很好的对密集目标进行跟踪, 跟踪性能要好于 JPDAF。在 MEF-JPDAF 的步骤 1 中, 不仅计算了量测与目标之间的隶属度, 还充分考虑了杂波的影响; 步骤 2~步骤 4 是对公共回波的权值进行衰减, 防止目标的交叉或合并, MEF-JPDAF 的计算量小, 计算量随着目标和有效回波的增长呈线性增加, 适合工程实现。

4.4 本章小节

本章针对杂波环境下的多目标数据关联问题, 采用了基于最大熵模糊聚类的数据关联算法。为了处理实时多目标跟踪中的数据关联问题, 利用修正的最大熵模糊聚类得到模糊隶属度作为回波与目标之间的关联概率, 并且充分考虑了杂波对目标航迹更新的影响。针对目标存在公共回波的情况, 算法对权值进行重新分配, 其主要思想是对只落入单个跟踪门的回波进行重加权, 对于落入多个跟踪门的回波进行轻加权。此外, 基于差异因子定义了最大有效距离 D_{\max} , 有效剔除无效观测, 提高了跟踪的精度, 减少了计算量, 能够实时对目标进行跟踪。

第五章 结束语

5.1 工作总结

数据关联作为多目标跟踪的核心技术之一，一直是国内外学者的研究热点，现在已经有很多研究成果成功应用于军事与民用领域。多目标跟踪技术作为信息融合系统的重要组成部分，其性能的好坏直接决定了信息融合系统的整体性能，对我国国防事业的建设有很重要的影响。本文围绕数据关联算法展开工作，重点研究了对联合概率数据关联算法的改进以及模糊聚类算法在数据关联中的应用，并仿真论证了算法的可行性。本文的具体内容主要有以下几个方面：

1. 多目标跟踪的基本理论与经典的数据关联算法。对多目标跟踪技术的基本理论进行了比较全面的叙述，包括航迹起始与终结、跟踪门技术、滤波与外推、目标运动模型；研究了最近邻算法、概率数据互联算法、联合概率数据互联算法、交互式多模型概率数据关联算法等经典的数据关联算法，对算法进行了仿真分析，讨论了使用的范围以及优缺点。
2. 针对 JPDA 算法计算量随着目标与回波数目的增加而急剧增长的问题，从两方面给出了解决方案。一方面，提出了改进的快速数据关联算法；另一方面，在传统的跟踪波门的基础上引入了方向跟踪门，使用双门限减少有效回波的个数，从而减小 JPDA 算法的计算量，最后对两种方案进行仿真验证。
3. 将模糊聚类算法引入数据关联中，针对杂波环境中目标跟踪的实时性问题，使用改进最大熵模糊聚类算法进行数据关联。仿真实验表明，该算法要优于传统的数据关联算法，能够对目标进行实时跟踪。

5.2 工作展望

本文简要阐述了多目标跟踪的基本原理，研究了经典的数据关联算法，针对 JPDA 算法存在的问题提出了改进算法，同时引入了最大熵模糊联合概率数据关联算法。本人认为这些算法在跟踪性能与实时性方面都是较好的方法，但是依然存在以下问题：随着杂波密度的增大、量测误差的增大，MJPDA 算法的稳定性、跟踪性能都会有所下降，导致目标的跟丢。这主要是由于对有效回波的权值进行处理时采用的是线性的衰减与增大，只能粗略地模拟权值的变化，但实际情况要远远比这复杂。在方向跟踪门中，有效回波的拟方向的计算存在很大的计算开销，在工程应用中应该进行适当的处理；其门限的选择也是一个值得进一步研究的问题。

题，如果选择的方向门限太大，会导致有效回波数目减少的趋势不明显，白白耗费计算量，如果选择的门限太小，会丢失真实量测，导致目标的丢失。

尽管已经有很多学者对数据关联算法进行了研究，提出了很多经典的算法，但数据关联仍然是一个相当有难度的课题，结合本人这两年的研究心得，认为自己应该在以上提到的方面继续努力，希望在将来能够很好的解决相关问题。

致谢

时光飞逝，不经意间两年半珍贵的研究生求学生涯即将结束。这是一段让人难忘的时光，让我受益匪浅。回首这段充实的求学之路，既有遭受失败时的迷茫与无奈，又有获得成功的喜悦与骄傲。在这段学习与科研期间，我取得的每一个进步与成功，包括论文的成功撰写，都离不开我的导师、同学、家人和朋友对我的指导、关心和帮助。在此，向他们表示我最衷心的感谢以及最崇高的敬意！

首先，要由衷地感谢我的导师李明教授！师者，传道、授业、解惑也。李老师以渊博的学识、严谨求实的治学、敏捷的思维、对工作的满腔热情以及丰富的科研经验，营造了民主、求是、自由的科研氛围，开拓了我的视野，培养了我对科研的兴趣，给我耐心细致的指导与思维上的启发。在整个研究生期间，李老师正直的人品、实事求是的治学态度、渊博的学术眼界，深深影响了我的人生态度，成为我宝贵的人生财富。在我整个研究生学习生活期间，特别是撰写论文的这段时间里，李老师给了我许多生活与学习上关心和帮助。在此谨向李老师致以崇高的敬意与深深的感谢！

其次，感谢我的校外指导老师—206所的阮锋高工。正是在阮老师的指导下，我才能迅速地将所学的理论知识运用于工程项目。同时，阮老师认真求实的工作态度以及诲人不倦的品质，是我人生宝贵的财富。

同时，感谢电子所的张林让教授、苏涛教授、罗丰教授、宋万杰教授、何学辉副教授等对我学习的热心指导与帮助。感谢实验室的白老师、刘老师、李老师、詹老师、程荣刚老师为我们提供了良好服务和科研条件。

感谢王亚军博士、张鹏博士、刘高峰博士、张晓伟博士、左磊博士、陈洪猛博士、卢云龙博士对我在科研和学习上的热心帮助和指导。感谢王姣、胡先伟、刘春明、董青海、张帆、张良才等朝夕相处的同学。感谢郑强师兄、崔子良师兄、李响师兄、腾飞师兄、邢璐师兄、罗小云师姐、葛佩师姐、刘翔师兄给予我学习上的指导。感谢贾璐、闫琰、周媛、高琪、欧旺军、牛龙、孙超、葛世超、吴钟国等师弟师妹的关心。祝愿各位师兄师姐师弟师妹工作顺利，学业进步。

非常感谢母校给了我学习的机会，西电深厚的文化底蕴，求实的学术氛围，使我受益匪浅。

我还要由衷地感谢我的父母。是你们养育了我，给了我现在所拥有的一切，感谢你们二十多年来为我所做的一切。非常感谢我的大哥，他对我精神上的激励、生活中的指导以及学习上的支持，对我的成长起到至关重要的作用。

最后，谨以该论文献给我的老师、同学、亲友！

参考文献

- [1] Singer R.A, Sea R.G.and Housewright K.B. A new Filter for Optimal Tracking in Dense Multitarget Enviroment , Proceedings of the Ninth Allerton Conference on Circuit and System Theory, Urbana, 1971: 201-211
- [2] Y.Bar-Shalom, T.E.Fortmann. Tracking and Data Association. Academic Press. 1988
- [3] Zhou B., Bose N.K. Multi-target Tracking in clutter: Fast Algorithms for Data Association [J]. IEEE Transactions on Aerospace and Electronic Systems.1993,29(2):352-363
- [4] 刘源. 基于模糊信息处理的数据融合方法研究[D]. 西安电子科技大学博士学位论文, 1999
- [5] 何友. 多目标多传感器分布信息融合算法研究[D]. 清华大学博士论文, 1996
- [6] 王国宏. 分布式检测、跟踪及异类传感器数据关联与引导研究[D]. 北京航空航天大学博士论文, 2002
- [7] 何兵. 多传感器数据融合领域若干问题的研究[D].北京航空航天大学博士论文, 2001
- [8] 刘宗香. 被动传感器组网系统目标探测与跟踪方法[D]. 西安电子科技大学博士论文,2005
- [9] 杨宏文. 多传感器目标跟踪理论与技术研究[D].国防科学技术大学博士论文, 2000
- [10] 韦毅. 红外无源定位技术研究[D]. 西安电子科技大学硕士论文, 2002
- [11] 严军,关键,彭应宁. 分布式检测系统的混合融合算法[J]. 清华大学学报(自然科学版). 2006, 46(1):46-49
- [12] 李辉,沈莹,张安. 机动目标跟踪中一种新的自适应滤波算法[J]. 西北工业大学学报. 2006, 24(3):354-357
- [13] 王泽毅. 多传感器协同目标跟踪方法研究[D]. 西安电子科技大学硕士论文. 2011.
- [14] 苏峰,王国宏,何友. 修正的逻辑航迹起始算法[J]. 现代防御技术, 2004.32(5):66-68
- [15] 何友,修建娟,张晶炜等. 雷达数据处理及应用.第二版.[M]. 北京: 电子工业出版社. 2009.pp:87-90
- [16] 程咏梅,潘泉,张洪才等. 基于推广卡尔曼滤波的多站被动式融合跟踪[J]. 系统仿真学报, 2003, 15(4):548-550.
- [17] 周荻,胡振坤,胡恒章. 自适应推广卡尔曼滤波应用与导弹的被动制导问题[J].

- 宇航学报, 1997, 18(4):31-36
- [18] S.J.Julier, J.K.Uhlmann. A New Method for the Nonlinear Transformation of Means and Covariances in Filters and Estimators [J]. IEEE Trans. on AC, 45(3), 2000: 477-482
- [19] Kishore Mehrotra, Pravas R. Mahapatra. A Jerk Model for Tracking Highly Maneuvering Targets [J]. IEEE Transactions on Aerospace and Electronic, 1997: 1094-1105
- [20] 欧阳成. 基于随机集理论的被动多传感器多目标跟踪[D]. 西安电子科技大学博士论文. 2012.
- [21] 宋骊平. 被动多传感器目标跟踪方法研究[D]. 西安电子科技大学博士论文. 2008.
- [22] T.Kirubarajan, Y.Bar-Shalom. Probabilistic Data Association Techniques for Target Tracking in Clutter [J]. Proceedings of the IEEE. March 2004, 92(3):536-557
- [23] 熊伟, 张晶炜, 何友. 修正的概率数据互联算法[J]. 海军工程学院学报, 2004, 19(3): 309-311
- [24] Blackman S.S. Multiple Hypotheses Tracking for Multiple Target Tracking [J]. IEEE AES MAG, 2004, 19 (1):5-18.
- [25] 李良群. 信息融合系统中的目标跟踪及数据关联技术研究[D]. 西安电子科技大学博士论文. 2007.
- [26] Mourad Oussalah, Joris De Schutter. Hybrid fuzzy probabilistic data association filter and joint probabilistic data association filter [J]. Information Sciences. 142(2002): 195-226
- [27] 邵滢滢, 陈小惠. 基于模糊聚类的数据关联融合算法[J]. 华东船舶工业学院学报(自然科学版), Dec. 2003, 17(6):58-62
- [28] 程婷, 何子述. 一种新的基于模糊聚类的多目标跟踪算法[J]. 系统工程与电子技术. Sep. 2006, 28(9): 1332-1352
- [29] 李洁, 高新波. 一种基于传感器加权的模糊聚类数据关联算法[J]. 电子学报. Dec. 2007, 35(12A):192-196
- [30] 韩红, 韩崇昭, 朱洪艳. 基于模糊聚类的异类多传感器数据关联算法[J]. 西安交通大学学报. Apr. 2004, 38(4):388-391
- [31] Ashraf M. Aziz, Tummala M. Fuzzy logic data correlation approach in multisensor-multitarget tracking systems [J]. Signal Processing. 1999, 76(2): 195-209
- [32] R. Mahler. Multi-target Bayes filtering via first-order multi-target moments [J].

- IEEE Transactions on Aerospace and Electronic Systems. 2003, 39(4), pp: 1152-1178.
- [33] B.N. Vo, W.K. Ma. The Gaussian mixture probability hypothesis density filter [J]. IEEE Transactions on Signal Processing. 2006, 54(11), pp: 4091-4104.
- [34] R. Mahler. PHD filters of higher order in target number [J]. IEEE Transactions on Aerospace and Electronic Systems. 2007, 43(4), pp: 1523-1543.
- [35] 董永强. 机动目标跟踪预测研究与应用[D]. 北京理工大学硕士论文. 2002.
- [36] T.Kirubarajan, Y.Bar-Shalom. Ground target with variable structure IMM estimator [J]. IEEE Transactions on Aerospace and Electronic Systems. 2000, 36(1):24-44
- [37] 梁彦,贾宇岗,潘泉. 具有参数自适应的交互式多模型算法[J]. 控制理论与应用. 2001,18(5): 653-656
- [38] Fitzgerald R J. Development of Practical PDA Logic for Multi-target Tracking by Microprocessor. Proc of American Control Conf, Seattle, WA,1986.
- [39] Zhou B, Bose N P. Multi-target Tracking in Clutter: Fast Algorithm for Data Association [J]. IEEE Trans on Aerospace and Electronic Systems. 1993,29(2):352-363
- [40] 程洪玮,周一宇,孙仲康. 快速 JPDA 算法的递归和并行实现[J]. 系统工程与电子技术. 1999,21(4):43-50
- [41] 袁刚才,吴永强. 密集杂波环境下的快速数据关联算法[J].系统仿真学报.2006, 18(3):561-564
- [42] 郑光海, 陈明燕,张伟. IMM 概率数据关联算法的多重门限研究[J].通信技术. 2010,43(7):228-232
- [43] 杨国盛,侯朝桢,窦丽华. 联合概率数据关联中双门限跟踪算法研究[J]. 系统工程与电子技术. 2002, 24(8): 87-90
- [44] Eng H L, Ma K K. Unsupervised Image Object Segmentation Over Compressed Domain [J]. Proc IEEE Int Conf Image Processing, 2000, (3):758-761
- [45] 李良群,姬红兵. 基于最大熵模糊聚类的快速数据关联算法[J]. 2006, 33(2):251-256
- [46] Liu Peter X, Meng Max Q.-H. Online Data-Driven Fuzzy Clustering With Applications to Real-Time Robotic Tracking. IEEE Transactions on Fuzzy Systems, Aug. 2004,12(4): 516 -523

作者在读期间的研究成果

一、 科研情况

参加科研项目：“某型号机载雷达信号处理机”研制

二、 学术论文

1. 吴佳芯，李明，董青海，一种基于最大熵模糊聚类的数据关联算法，雷达科学与技术，已投。
2. 董青海，李明，吴佳芯，一种基于广义旁瓣相消器的快速降秩算法，雷达科学与技术，已投。